貴州大學

2026届硕士学位论文

面向天文领域知识增强的大语言模型问答技术研究

学科专业：电子信息

研究方向：计算机技术

中国 ▪ 贵州 ▪ 贵阳

2026年3月

第一章　绪论

1.1 研究背景与意义

1.1.1 天文学数据密集型科研范式的转变与知识获取的挑战

天文学作为一门以观测为基础的自然科学，正处于从传统的“理论推导与计算模拟”向“数据密集型科学发现”（Data-Intensive Scientific Discovery），即“第四范式”深刻转型的历史节点。随着观测技术的飞速跃迁，人类探索宇宙的视野已从单一的光学波段拓展至全波段、多信使（Multi-messenger）时代。

（1）天文数据的体量正经历着前所未有的爆炸式增长

以郭守敬望远镜（LAMOST）、中国天眼（FAST）为代表的地面巡天设备，以及盖亚卫星（Gaia）、詹姆斯·韦伯太空望远镜（JWST）等空间观测设施，每天都在产生海量的观测数据。即将投入运行的中国空间站巡天望远镜（CSST）和平方公里阵列射电望远镜（SKA），预计将把数据流提升至 EB（Exabyte）量级。这种从“样本观测”到“全天域巡天”的模式转变，使得科研人员面对的不再是匮乏的数据，而是如何从海量、高维且高速增长的多源异构数据中筛选有效信息的巨大挑战。

（2）天文知识呈现出高度的多源异构（Multi-source Heterogeneity）与碎片化特征，形成了严重的“数据孤岛”，天文学的知识并非存储于单一介质中，而是广泛分布在形态各异的载体里：

a. 非结构化文本：最新的理论突破和物理机制解释沉淀在 arXiv、ADS（Astrophysics Data System）等平台的数百万篇科研论文中，且以每天数百篇的速度持续更新。
b. 半结构化/结构化数据库：恒星的物理参数（如光谱型、金属丰度）存储于 Simbad、VizieR 等专业星表数据库中；
c. 多模态观测数据：天体的直观形态存在于 FITS 图像中，而演化规律则隐含在光谱序列和光变曲线（Light Curves）的时间序列数据里。

这些数据源之间缺乏统一的语义链接，科研人员为了研究一个具体天体（如“参宿四”），往往需要在文献库中检索物理机制，再跳转至星表库查询精

确坐标和视差，最后在观测库下载光谱数据。这种割裂的知识获取路径极大地增加了科研的时间成本。

（3）人类专家的认知带宽已无法跟上知识产出的速度，导致了严重的“知识利用瓶颈”。

面对指数级增长的文献和数据，依靠人工阅读、记忆和手动关联的传统科研模式已难以为继。研究表明，大量珍贵的科学发现可能正隐性存在或尚未被挖掘在既有的数据和文献中，仅因缺乏有效的整合手段而未被发掘。例如，时域天文学（Time-Domain Astronomy）要求对瞬变天体（如超新星爆发、引力波事件）做出近乎实时的响应与分析，这要求知识获取系统必须具备毫秒级的信息聚合与推理能力。

因此，迫切需要一种智能化的技术手段，能够打破数据模态的壁垒，自动聚合分散的异构知识，并将静态的非结构化数据转化为动态的、结构化的可推理知识表征，从而辅助天文学家在第四范式时代高效地进行科学探索。

1.1.2 LLM 在垂直领域应用中的事实一致性与可解释性瓶颈

近年来，以 Transformer 架构为基石的大语言模型（Large Language Models, LLMs），如 GPT-5、DeepSeek、Gemini 等，展现出了惊人的自然语言理解、生成与泛化能力，被视为通往通用人工智能（AGI）的重要里程碑。然而，当我们将这些在通用语料上训练的模型直接“移植”到对精确度有着苛刻要求的天文学垂直领域时，其固有的技术缺陷便被无限放大，形成了制约其落地的两大核心瓶颈。

（1）事实一致性（Factual Consistency）的缺失，即严重的“幻觉”问题

LLM 本质上是一个基于概率统计的“下一个词预测器”，其知识以隐式的权重形式存储于参数化记忆（Parametric Memory）中。这种机制导致模型在处理专业科学问题时，往往表现出“一本正经地胡说八道”。在天文学场景下，这种幻觉主要体现在三个方面：

a. 数值捏造：天文学是一门定量的科学。当询问模型“天狼星 B 的表面温度是多少”时，模型可能会根据概率生成一个看似合理的数值（如 10,000K），而实际上该数值可能与真实观测值（约 25,200K）相去甚远。这种数值上的偏差在科学计算中是不可接受的。

b. 长尾知识混淆：对于著名的天体（如太阳、黑洞），模型可能回答准确；但面对数以亿计的长尾天体，模型极易将其属性与其他热门天体张冠李戴。

c. 知识时效性滞后：天文学发现日新月异（如新的系外行星被确认），而 LLM 的训练数据截止于特定时间点（Knowledge Cutoff），导致其无法回答基于最新观测成果的问题，甚至会用过时的理论来解释新的现象。

（2）可解释性（Interpretability）与可追溯性（Traceability）的严重不足

科学研究的核心精神在于“大胆假设，小心求证”，任何科学结论的得出都必须伴随着严密的证据链（Evidence Chain）。然而，端到端的 LLM 推理过程如同一个不透明的“黑盒”，当模型给出一个关于“恒星演化模型”的解释时，用户无法得知这一观点是引用自经典的教科书，还是某篇未经同行评审的预印本论文，抑或是模型自行拼凑的语义片段。模型往往直接给出最终答案，而隐藏了中间的推导步骤。科研人员无法验证模型是否正确使用了物理公式，或者是否在逻辑推演中引入了错误的假设。

这种缺乏透明度的“黑盒”属性，使得 LLM 在科研辅助中面临信任危机。在辅助撰写论文或进行数据分析时，如果无法提供可供查证的原始文献出处和清晰的逻辑路径，科研人员就不敢轻易采信模型的输出。因此，如何让 LLM 从一个“概率生成器”转变为一个“可信赖的科研助手”，是当前亟待解决的关键技术难题。

1.1.3 知识增强生成从单纯文本检索向结构化知识推理的演进

为了缓解大语言模型的幻觉问题并赋予其外部知识访问能力，检索增强生成（Retrieval-Augmented Generation, RAG）技术应运而生并迅速成为行业标准范式。然而，随着应用场景从通用的开放域问答深入到专业的天文学科研问答，传统的 RAG 技术正面临着从“非结构化文本检索”向“结构化知识推理”演进的迫切需求。

传统的 RAG 系统主要依赖稠密向量检索（Dense Retrieval），通过计算查询（Query）与文档块（Chunk）之间的语义相似度来召回信息。这种机制在处理描述性问题时表现尚可，但在面对天文学中严谨的数值关系和逻辑约束时往往失效。

（1）数值敏感性缺失：例如，当用户询问“质量大于 10 倍太阳质量的恒星演化终局”时，向量检索可能会召回包含“质量”、“太阳”、“恒星”等关键词但数值范围不符（如讨论小质量恒星）的文档，导致模型基于错误的上下文进行生成。

（2）实体消歧困难：天文学中存在大量名称相近但物理性质迥异的实体（如“仙女座星系”与“仙女座流星雨”）。单纯的文本检索容易引入噪声文档，干扰模型的判断。

天文学问题的解决往往依赖于“先检索后计算”的复杂多跳推理，而非简单的“检索即答案”。科研中的问题通常不是直接陈述事实，而是需要跨越多个知识点进行逻辑推演。例如，回答“计算距离地球最近的红超巨星的切向速度”这一问题，系统不能指望在某篇文档中直接找到现成的答案，而必须执行一系列结构化的操作：

（1）实体识别与属性检索：首先识别出“参宿四”（Betelgeuse）是符合条件的实体；

（2）多源参数获取：从星表数据库中分别检索其“自行”（Proper Motion）和“距离”（Distance）两个独立的数值参数；

（3）符号化计算：调用物理公式 $vt=4.74\times\mu\times d$

（4）进行精确的数值运算

这种跨文档的信息整合、参数提取与符号计算，超出了非结构化文本 RAG 的能力范畴。因此，RAG 技术必须向基于结构化知识图谱（Knowledge Graph, KG）的推理演进。知识图谱以（实体, 关系, 实体/属性值）的三元组形式，将隐式的文本知识转化为显式的结构化知识。引入 KG 对 RAG 进行增强具有三重核心优势：

a. 精确的知识锚点：KG 提供了唯一的实体 ID 和确定的属性数值，有效解决了实体消歧和数值模糊问题。
b. 显式的推理路径：图谱的拓扑结构天然支持多跳推理，使得模型可以沿着关系边（如“属于类别”、“位于星座”）进行可解释的逻辑游走。
c. 神经与符号的融合：将 LLM 强大的语义理解能力与 KG 严谨的逻辑结构相结合，既保留了生成的灵活性，又确保了推理的鲁棒性。

1.2 国内外研究现状

1.2.1 大语言模型在科学领域的应用与挑战

过去三年中，大语言模型（Large Language Models, LLMs）的角色发生了根本性的转变，迅速从通用的文本生成与对话工具，扩展为科学研究中的“智能接口”与“科研助理”。在这一进程中，业界与学术界逐渐分化出两条并行的发展路径：一是以 GPT-4 [3] 为代表的通用巨模型（Generative Foundation Models），其强调跨领域的通用推理能力与多模态表征；二是以 Galactica[1]、AstroLLaMA[2] 为代表的科学垂直模型（Domain-specialized Foundation Models），其核心在于通过指令微调，将科学符号（如 LaTeX 公式、化学分子式）、参考文献结构以及专业术语编码进模型的参数空间 。尽管 DeepSeek 等新兴产业模型在推理效率与本地化部署上展示了快速迭代的能力 [14]，但将这些模型应用于天文学等对精确度有极高要求的科学领域，仍面临着应用潜力与技术瓶颈并存的复杂局面。

在天文学的数据密集型研究中，LLM 的应用已渗透至从文献调研到数据分析的多个环节，具体表现为以下三个层面：

（1）文献自动摘要与知识抽取：面对 arXiv 每天数以百计的新增论文，科研人员的阅读负荷已达极限。研究表明，经过天文学语料（数万篇摘要）微调的模型（如 AstroLLaMA），在理解天体物理概念、提取观测参数（如红移、光度）以及构建问答式检索界面方面，显著优于未经微调的通用模型 [2]。这些模型不仅能生成高质量的综述摘要，还能辅助构建领域知识图谱，量化评估模型在天文事实性上的表现已成为新的研究热点 [9][10]。

（2）科学代码生成与数据分析辅助：LLM 在辅助编写天文数据处理脚本方面展现了巨大潜力。通过在代码数据上进行微调，模型能够熟练调用 Astropy、NumPy 等专业库，自动生成用于数据清洗、光变曲线绘图或仪器控制的模板代码 [8]。然而，实证研究指出，虽然模型在生成“模板式”代码时效率极高，但在涉及严谨的数值处理（如误差传播计算、复杂的单位换算、高精度算法选择）时，仍需科研人员进行严格的人工核验，以防逻辑陷阱。

（3）科普问答与公众交互：天文科普是 LLM 落地风险相对较低的场景。

通过检索增强技术，模型能够将晦涩的 FITS 图像数据或光谱分析结果转化为通俗易懂的自然语言解释，极大地降低了公众理解宇宙奥秘的门槛。但即便在此类场景中，模型偶发的“自信但错误”的幻觉（如编造某颗恒星的发现历史）仍可能误导公众，因此目前的最佳实践通常要求配合来源引用与置信度提示进行部署 [11]。

尽管 LLM 在处理语言类任务上表现卓越，但其底层架构决定了在面对天文学核心的“定量计算”与“事实查证”任务时，存在两大难以克服的内生性缺陷：

数值精度（Numerical Precision）的系统性缺失：天文学是一门建立在精确测量基础上的科学，而 Transformer 架构本质上是基于概率的“标记（Token）预测器”，而非逻辑严密的“计算器”。预训练语料中的数字分布并不遵循科学测量的统计规律，导致模型学习到了错误的“数字生成先验”（Digit Bias）。例如，模型可能受训练语料中常见数字的影响，倾向于生成“圆整”的数值而非精确的观测值 [12]。基准测试（如 GSM8K, MATH）显示，即使是顶尖模型在处理多步骤数学推理、边界条件判断及单位一致性检查时，仍有显著的失败率 [7]。在 2024-2025 年的专门性数值基准评估中，LLM 在实际科学计算需求下的脆弱面被进一步揭示 [13]。这意味着单纯依靠参数记忆，无法满足科研级的数值稳定性要求。

长尾科学知识与幻觉（Hallucination）：幻觉是限制 LLM 在科研场景信任度的最大障碍，即模型生成内容通顺但事实错误、或无法追溯来源的信息 [6]。天文学包含海量的“长尾”知识（如特定变星的光变参数、稀有物理常数的最新测量值）。在这些预训练语料覆盖不足的低资源区域，模型极易利用“最有可能的语言模式”来填补知识空白，从而产生难以察觉的错误 [11]。单纯依赖模型参数记忆（即“把知识存进权重”）导致知识无法实时更新，且缺乏可追溯性与可验证性。近期基于语义熵（Semantic Entropy）的研究表明，幻觉的产生是数据偏差与模型采样策略共同作用的结果 [5]。这种“黑盒”特性与科学研究对可复现性（Reproducibility）与可审计性（Auditability）的根本要求相悖。

1.2.2 知识图谱自动化构建与动态演化技术

近年来，知识图谱构建技术正经历着从依赖人工规则与统计模型的传统方法，向以大语言模型（Large Language Models, LLMs）为核心的生成式自动化

范式转变[15–17]。尤其在科学文献等高度非结构化、语义复杂且知识快速演化的文本场景中，如何实现高精度的信息抽取、灵活的本体归纳以及具备时效感知能力的动态维护，已成为当前知识图谱研究领域的关键问题[18–20]。

（1）基于 LLM 的信息抽取：从流水线到端到端范式的转变

信息抽取（Information Extraction, IE）是从非结构化文本中识别并结构化表示实体、关系及其属性的核心技术，是知识图谱构建的基础环节[1]。

传统流水线方法的局限性：早期信息抽取研究通常采用流水线（Pipeline）范式，将整体任务拆分为命名实体识别（NER）和关系抽取（RE）等多个子任务，并分别进行建模与优化[15,16]。尽管该方法在系统设计上具有模块清晰、易于实现的优势，但其不足亦十分突出。一方面，流水线结构不可避免地引入错误传播（Error Propagation）问题，实体识别阶段的错误会直接传递至关系抽取阶段，导致整体性能受限[2]；另一方面，子任务之间缺乏联合建模机制，难以充分捕捉实体与关系之间的交互语义信息。此外，该类方法通常对高质量标注数据依赖较强，在开放领域或专业语料中泛化能力有限[17]。

基于指令微调的端到端抽取范式：随着预训练语言模型规模和能力的显著提升，研究者开始探索基于生成式建模的端到端信息抽取方法[17]。该类方法通常借助指令微调（Instruction Tuning）技术，将实体抽取、关系抽取乃至事件抽取等任务统一转化为序列生成问题[17,18]。通过显式设计 Schema 指令或结构化提示（Prompt），模型能够直接生成符合预期格式的结构化结果，如实体—关系三元组或 JSON 表达[18,19]。已有研究表明，此类方法在零样本（Zero-shot）和少样本（Few-shot）场景下具有显著优势，能够有效降低对人工标注数据的依赖，并提升模型在跨领域任务中的适应能力[19,20]。

现有方法面临的挑战：尽管基于 LLM 的端到端信息抽取在灵活性和泛化能力方面取得了显著进展，但在处理科学文献等长文本和复杂语义场景时仍存在不足。例如，生成式模型可能产生与原文不一致的“幻觉”信息，导致抽取结果的可靠性下降；同时，模型对复杂结构化约束（如嵌套实体、多关系共存）的遵循性仍不稳定[21]。

（2）开放域本体归纳：无预定义 Schema 下的自适应发现

在天文学等知识演化迅速、探索性较强的科学领域，预先构建一套完备且稳定的本体 Schema 往往难以实现，因此在缺乏预定义 Schema 的条件下自动发

现新的实体类型与关系类型，成为知识图谱构建中的关键问题[20,21]。开放信息抽取（Open Information Extraction, OpenIE）方法通过直接从文本中抽取“主体–谓语–客体”三元组，在一定程度上摆脱了对预定义本体的依赖[21,22]。然而，由于其抽取的关系通常以自然语言短语形式存在，缺乏统一的语义规范，导致图谱中关系表达高度碎片化，语义冗余严重，从而限制了图谱在推理与结构分析任务中的应用效果[22,23]。近年来，研究者开始利用 LLM 在语义理解和抽象概括方面的能力，探索开放域本体归纳（Open Schema Induction）方法[18,19]。该类方法通过引导模型对实体和关系进行语义聚类、概念概括或标签生成，实现对新类型和新关系的自适应发现，从而推动知识图谱结构随数据不断演化[5]。尽管基于 LLM 的开放 Schema 归纳在提升知识覆盖率方面表现出潜力，但在专业性较强的科学语料中，模型仍难以准确把握概念粒度与类型层级，容易产生类型混淆和同义概念未对齐等问题[20]。此外，现有方法普遍缺乏与领域知识相结合的约束机制，限制了归纳结果的稳定性与可解释性。

（3）图谱的动态更新与维护：增量构建与冲突处理

知识图谱并非静态知识库，而是需要随着新数据和新发现的出现持续演化的动态系统[24]。在面对大规模且持续增长的文本数据时，全量重构知识图谱在计算和存储成本上难以接受，因此增量式构建（Incremental Construction）逐渐成为主流研究方向[24,25]。相关研究通常结合持续学习（Continual Learning）或在线学习机制，试图在引入新知识的同时，通过增量蒸馏等手段缓解模型对旧知识的灾难性遗忘（Catastrophic Forgetting）问题[25,26]。在科学研究领域，新发表的成果可能会对既有知识进行修正甚至推翻，而现有增量更新方法多聚焦于“新增”知识的接入，对已有实体和关系的修改、替换及冲突消解关注不足[24]。当前主流知识图谱更新框架普遍缺乏对知识时效性和可信度的精细化建模。当新抽取知识与图谱中已有信息发生冲突时，系统往往难以自动判断其来源于语义歧义、抽取噪声还是知识本身的演化，从而导致图谱中逐渐积累过时或矛盾的信息[25,26]。

1.2.3 检索增强生成（RAG）与图检索增强生成（GraphRAG）

检索增强生成（Retrieval-Augmented Generation, RAG）通过将外部非参数化知识库与大规模语言模型（LLM）联合使用，以减轻模型参数记忆的局限并

提高生成内容的事实性，已成为知识密集型自然语言处理任务中的重要范式。早期系统化提出 RAG 的工作指出，将稠密检索器与生成式模型结合，可在开放域问答等任务上显著提升性能与可追溯性 [28]。

（1）非结构化文本 RAG（Vector-based RAG）

基于非结构化文本的 RAG 通常利用密集向量检索（Dense Vector Retrieval）或稀疏检索（如 BM25、TF-IDF）从大规模文档库（如 Wikipedia [40]）中召回相关段落，并将这些段落作为生成模型的证据上下文以约束输出。代表性工作如 Dense Passage Retrieval （DPR） 展示了利用双编码器训练得到的向量检索器，在召回率上显著优于传统稀疏方法，从而推动了端到端检索—生成系统的进步 [29]。

然而，向量相似度检索在处理多跳（Multi-hop）或需要精确逻辑与时序关系的任务中存在两类典型局限：

a. 语义漂移（Semantic Drift）： 在检索或后续的链式推理过程中，检索目标可能逐步偏离原始问题的核心意图，导致召回内容与问题相关性下降 [41]。

b. 细节丢失与证据链断裂： 向量压缩与文本切分可能导致关键事实片段无法完整呈现。为缓解这些问题，研究者提出了交互式检索与检索引导的思维链（Interleaved Retrieval with CoT）等策略，强调检索应与推理步骤互为条件，从而减少漂移与信息缺失 [32]。

（2） 结构化 GraphRAG（KG-based RAG）

基于知识图谱（Knowledge Graph, KG）的 GraphRAG 方法利用实体与关系的显式拓扑信息，通过子图检索、路径搜索或基于图的子结构将结构化事实直接提供给生成模型，从而提高推理的可解释性与逻辑一致性。此类方法的构建往往依赖于底层的信息抽取技术 [27]。早期的多源融合方法，如 GRAFT-Net [30, 38] 和 PullNet [31]，通过在问题特定的子图上进行图神经网络建模或迭代检索，证明了将结构化三元组与文本联合建模能显著改善多跳问答的精度与可解释性。这些方法通常基于 Wikidata [39] 等大规模知识库进行实验。

GraphRAG 类方法的优势在于能够显式呈现“实体→关系→实体”的推理链路，便于验证与溯源。然而，其瓶颈在于知识图谱的覆盖率与完整性。当关键实体或关系在 KG 中缺失时，基于路径的推理会中断；此外，许多方法依赖准

确的实体消歧作为启动点，实体识别错误会导致错误沿路径放大。因此，单靠 KG 的方法在面对实际开放世界数据时，往往需要结合 LLM 的内隐知识或文本检索作为补偿以提升鲁棒性。

（3）混合检索范式（Hybrid Retrieval）

鉴于文本检索与 KG 检索各有优势，近年大量工作提出将两者混合的范式：一方面利用图结构提供严格的关系约束与可解释子图，另一方面利用文本检索补齐 KG 的长尾信息与上下文细节。例如，HybridRAG [36] 和 GRAG [35] 分别探索了在单一检索回合中并行或分层整合子图检索与段落检索，以及如何将检索到的子图以“文本或图两视图”的形式供 LLM 消费，从而在覆盖率与结构化推理间取得平衡。这些混合策略通常致力于解决以下问题：如何度量并融合来自向量检索与子图检索的异构证据；如何在检索结果间检测并处理证据冲突；以及如何设计有效的检索—验证闭环以避免早期错误的级联效应。

（4）迭代检索、检索—推理交互与自反机制

为降低检索误导与推理中错误的累积，研究者提出了一系列动态与迭代检索框架。基于思维链（Chain-of-Thought, CoT）提示能有效激发 LLM 推理能力的发现 [37]，IRCoT [32] 进一步将 CoT 与逐步检索交织，使“已推导的中间结论”指导下一步检索，从而提高多步问题的证据召回与事实一致性。此外，SELF-RAG [33] 引入了“自我反思/反省 token”机制，让模型在生成过程中自主判断何时需检索，并对检索到的片段进行质量评估与批判。HippoRAG [34] 等工作则尝试受神经生物学启发，在检索层面构建长期记忆索引或一次性压缩多跳路径检索以提高效率。上述方法共同表明，在 RAG 系统中将检索与推理视为交互式、可迭代的闭环，并引入显式的证据验证或自我纠错机制，是提升多跳推理可靠性与可解释性的有效方向。

1.2.4 复杂逻辑推理与自纠错机制

随着大语言模型在开放域问答与知识密集型任务中的广泛应用，如何引导模型进行稳定、可控的复杂逻辑推理已成为当前研究的重点。现有工作主要从思维链的显式化与结构化、复杂问题的分解策略，以及推理结果的验证与自纠错机制三个维度展开，旨在缓解长链条推理过程中常见的错误累积与不可解释性问题。

（1）思维链（Chain-of-Thought）及其结构化演进

思维链（Chain-of-Thought, CoT）作为一种显式建模推理过程的范式，通过引导模型生成中间推理步骤，将复杂问题拆解为一系列逻辑连贯的子推断，显著提升了模型在数学推理和多步问答任务中的表现 [42]。后续研究进一步发现，即便在零样本（Zero-Shot）设置下，通过简单的提示引导（如“Let's think step by step”），LLM 也能展现出强大的推理能力，这表明模型内部已具备潜在的逻辑连接能力 [43]。

然而，传统的线性 CoT 在面对高度复杂的问题时仍存在局限：一旦早期的推理步骤出现偏差，后续推理往往不可逆地沿错误路径展开（Cascading Errors）。为此，研究者提出了更具结构性的推理范式。思维树（Tree of Thoughts, ToT）通过在推理过程中显式维护多个候选思路，并结合广度优先搜索（BFS）或深度优先搜索（DFS）策略进行路径选择，使模型能够在不同推理分支之间进行比较、评估与回溯，从而大幅提升了复杂任务的鲁棒性 [44]。在此基础上，思维图（Graph of Thoughts, GoT）进一步将推理过程建模为任意图结构，允许不同推理子路径共享中间结论并进行交叉验证，更适合表达非树状的复杂依赖关系 [45]。这些方法共同表明，将推理过程从单一的线性序列扩展为结构化的搜索空间，是缓解多跳推理中错误传播的有效途径。

（2） 问题分解技术（Decomposition）

除了显式建模推理结构外，问题分解（Decomposition）被认为是解决复杂推理任务的另一关键手段。Least-to-Most Prompting 提出了一种“由易到难”的策略，先引导模型将原问题拆解为一系列子问题，再逐步利用前序子问题的答案来辅助后续推理，从而显著提升了模型在组合性泛化任务中的稳定性 [46]。与直接 CoT 相比，该方法在长推理链场景下更不易因单步错误而导致整体失败。

在开放域与多跳问答任务中，问题分解常与检索过程紧密结合。例如，IRCoT（Interleaving Retrieval with CoT）通过交替执行检索与推理步骤，利用当前推理状态生成的子查询来检索下一步所需的证据，从而实现了推理与检索的动态交互 [47]。这种“分而治之”的策略不仅有助于提高证据的覆盖率，也在一定程度上降低了语义漂移的风险。然而，分解的粒度与子问题的生成顺序通常依赖于启发式规则或模型自身的先验知识，如何保证分解过程的逻辑正确性仍是一个开放性问题。

（3） 推理的验证与自纠错（Verification & Self-Correction）

即使采用了结构化推理或问题分解，模型生成的中间结论仍可能与事实不符。因此，近年来大量研究开始关注推理结果的验证与自纠错机制。一方面，基于外部证据的验证（Evidence-based Verification）通过将模型生成的结论与检索到的证据进行对齐检查，以判断推理的可信度。例如，Self-RAG 引入了特殊的“反思标记（Reflection Tokens）”，使模型能够自主判断是否需要检索、检索内容是否相关以及生成结果是否被证据支持，从而在发现冲突时触发重新检索或修正 [48]。另一方面，部分研究探索了模型内部的反思与纠错能力。ReAct 框架将推理（Reasoning）与行动（Action，如调用搜索工具）交替执行，使模型能够根据环境反馈动态调整推理路径，形成“观察—思考—行动”的闭环 [49]。Reflexion 则进一步引入了语言强化学习的思想，引导模型在生成答案后对自身的推理过程进行回顾与批判，通过言语反馈（Verbal Reinforcement）来诱导自我纠错 [50]。在多跳问答与代码生成任务中，这类自反机制被证明可以在无需额外监督数据的情况下，有效提升答案的准确率与逻辑一致性。

总体而言，现有研究正逐步从“生成一次性推理链”转向“推理—验证—修正”的动态闭环范式。如何在复杂推理过程中有效融合结构化思维链、问题分解策略与基于证据的验证机制，以降低错误累积并提升推理的可靠性，是当前研究的核心方向。

1.2.5 基于大模型的智能体（Agent）协同技术

随着大语言模型（LLM）在推理与规划能力上的突破，智能体（AI Agent）已从单一的文本生成工具演进为具备感知、决策与执行能力的自主系统。当前研究主要集中在提升单智能体的工具使用能力以及构建多智能体协同系统以解决复杂任务。

（1）单智能体工具调用能力

大语言模型作为智能体的“大脑”，通过调用外部工具（Tools）或应用程序接口（API），能够有效突破参数化知识的局限，获取实时信息并执行精确计算。 传统的工具调用往往依赖大量人工标注数据进行监督微调。针对这一问题，Schick 等人提出了 Toolformer 框架，通过自监督的方式让模型“自学”工具使用 [51]。该方法通过在预训练语料中采样并插入潜在的 API 调用序列，利用

模型自身的预测能力过滤出有助于降低困惑度（Perplexity）的调用，从而使模型在无需大量人工干预的情况下掌握计算器、搜索引擎等工具的使用模式。为了增强智能体在复杂任务中的鲁棒性，Yao 等人提出了 ReAct（Reasoning and Acting）范式 [52]。不同于单纯的推理（如 Chain-of-Thought）或单纯的行动，ReAct 要求 LLM 在生成过程中交替输出“思考（Thought）”与“行动（Act）”，并根据工具返回的“观察（Observation）”动态调整后续计划。这种“推理—行动—观察”的闭环机制不仅提高了模型的可解释性，还显著减少了事实性幻觉，在 HotpotQA 等多跳问答及 ALFWorld 等决策任务中均取得了优于基线的效果。

（2）多智能体协作系统（Multi-Agent Systems）

面对跨领域、长流程的复杂任务（如软件开发、科学研究），单智能体容易受限于上下文窗口或陷入逻辑死循环。多智能体协作系统（Multi-Agent Systems, MAS）通过引入角色扮演（Role-Playing）与通信机制，模拟人类团队的分工协作，成为当前的研究热点。 Hong 等人提出的 MetaGPT 框架将人类社会的标准化作业流程（Standard Operating Procedures, SOPs）编码进智能体系统 [53]。通过定义产品经理、架构师、工程师等特定角色，并设计结构化的通信协议（如需求文档、设计图纸），MetaGPT 能够将抽象需求转化为具体的软件工程任务。这种装配线（Assembly Line）式的协作模式有效约束了智能体的行为空间，显著提升了长程任务生成的连贯性与正确率。对话式交互与动态协作： 微软提出的 AutoGen 框架则探索了更为灵活的对话式协作范式 [54]。该框架允许开发者定义多个具有不同系统提示（System Prompt）和工具权限的智能体（如 Conversable Agent），并通过自动化的对话流实现任务求解。Li 等人提出的 CAMEL 框架进一步验证了“角色扮演”机制的有效性，通过引导两个智能体（如用户与助手）在特定情境下进行指令跟随与交互，能够激发模型涌现出单智能体难以具备的复杂规划能力 [55]。

1.2.6 问答系统评测基准与评估方法

构建高质量的评测基准与科学的评估体系，是衡量问答系统在垂直领域推理能力的关键。现有的评测体系经历了从通用领域向科学领域、从基于统计匹配向基于模型深度评估的演进，但在数值计算与证据链验证方面仍存在显著空

白。

（1）通用问答数据集及其在科学领域的局限性

通用领域的问答数据集为多跳推理研究提供了基础，但在面对天文学等专业科学场景时表现出明显的适应性不足。

基于知识库的问答（KBQA）： WebQSP 是基于 Freebase 知识图谱构建的经典数据集，提供了精确的逻辑形式（Logic Form）标注 [56]。然而，由于 Freebase 已停止维护，其科学实体覆盖率严重滞后，且 WebQSP 中约 30% 的问题仅需单跳推理，难以考察涉及复杂因果链条的深度逻辑。

基于文本的多跳问答： HotpotQA 要求模型综合多个维基百科文档进行推理，并引入了“联合 F1（Joint F1）”指标以同时评估答案与支撑句 [57]。尽管其推动了多跳推理技术的发展，但其数据源主要为半结构化百科文本，缺乏科学文献中常见的实验表格与数学公式。此外，HotpotQA 的问题设计多侧重于常识性关联，难以支持需要严谨数值比较或假设验证的科学推理任务。

（2）垂直领域与科学评测基准的缺失

针对科学领域的问答数据集虽然引入了专业术语，但在考察数值计算（Numerical Reasoning）与跨文档逻辑（Cross-document Logic）方面仍显薄弱。

数值计算能力的缺失： SciQ 数据集涵盖了物理、化学等学科的考试题，但主要采用多项选择题形式 [58]。研究表明，模型往往通过选项排除法而非主动计算来作答，导致该数据集无法有效评估模型在复杂公式应用、单位换算及实验数据拟合方面的真实能力。

跨文档推理的局限： PubMedQA 聚焦于生物医学领域，要求模型根据论文摘要判断结论（Yes/No/Maybe）[59]。然而，其任务本质被限制在单篇文档的上下文内，且分类任务的形式限制了对推理深度的考察。在天文学研究中，问题往往需要跨越文献（Text）与数据库（Database）进行联合推理（如结合论文中的理论模型与星表中的观测数据），现有的科学评测基准难以覆盖此类异构多模态场景。

（3）评估指标的演进：迈向白盒化证据链评估

问答系统的评估指标正经历从“文本重叠”到“逻辑验证”的深刻变革，强调对推理过程的白盒化审计。

传统统计指标的失效： 早期的 BLEU 和 ROUGE 指标基于 N-gram 词汇重叠计算相似度 [60][61]。在科学问答中，这些指标无法识别数值错误（如“1000K”与“10000K”仅差一字但物理意义迥异）或逻辑谬误，导致“答案正确但推理错误”的现象无法被检测。

基于模型的深度评估： 随着 LLM 能力的提升，LLM-as-a-Judge 范式逐渐成为主流，即利用强模型（如 GPT-4）作为裁判对生成质量进行打分 [61]。RAGAS 框架进一步提出了检索相关性、忠实度（Faithfulness）等细粒度指标，用于评估 RAG 系统的中间过程 [63]。

白盒化证据链评估的重要性： 针对科学研究对严谨性的极高要求，单纯的端到端评分已不足够。未来的评估趋势是建立白盒化证据链（White-box Evidence Chain）验证机制，即要求模型不仅输出最终答案，还需展示完整的推理路径（如检索到的具体参数来源、使用的计算公式及中间结果）。通过对比模型生成的推理树与专家标注的“黄金推理链”，可以更精准地定位逻辑断裂点，提升系统的可解释性与可信度。

1.3 本文的研究目标与内容

1.3.1 研究目标

本研究旨在解决通用大语言模型在天文学垂直领域应用中存在的幻觉严重、知识更新滞后以及推理过程不透明等核心问题。通过深度融合大语言模型的语义理解能力与知识图谱的结构化逻辑优势，构建一套“评测基准-知识构建-推理算法”闭环的天文智能问答技术体系。具体目标包括：

（1）建立标准：构建一套能够客观评价大模型在天文领域复杂推理能力的评测基准，填补现有评测体系在数值计算与多跳逻辑方面的空白。

（2）动态沉淀：实现天文领域海量异构数据的自动化结构化提取与动态图谱维护，解决知识时效性与一致性难题。

（3）精准推理：研发高鲁棒性、可解释的问答推理算法，显著提升系统在处理天文复杂科学问题时的准确率与可信度。

1.3.2 研究内容

围绕上述目标，如图 1-1 面向天文领域的知识增强问答技术体系架构所示，本文的主要研究内容包括以下三个方面：

图 1-1 面向天文领域的知识增强问答技术体系架构

（1）面向天文领域的数值计算与多跳推理评测基准构建

针对现有问答数据集难以有效评估模型在科学领域复杂推理能力的问题，本研究将构建一个专注于天文场景的评测数据集。

a. 异构数据整合：整合 Simbad 高精度观测数据与 Wikidata 结构化知识，清洗并标准化数值单位与实体名称。

b. 复杂逻辑生成：设计涵盖属性比较、隐式公式计算、多跳关系溯源等 5 大类高阶推理模板，生成具有挑战性的原始问答对。

c. 对抗性难例挖掘：利用大模型进行对抗性测试，筛选出模型依靠内部参数记忆无法回答或容易产生幻觉的“难例”样本。

d. 全链路标注：为每个问题提供包含检索参数、计算公式及完整推理路径的白盒化证据链，形成 AstroRAG-600 评测基准。

（2）基于多智能体协同的天文知识图谱动态构建与演化

针对天文文献非结构化程度高、术语更新快导致的图谱构建难题，本研究将设计一个基于多智能体协作的自动化图谱构建系统。

a. 多智能体架构设计：定义数据侦察员、信息提取员、知识审核员与图谱架构师等智能体角色，通过协作完成数据流转。

b. 自适应图谱探测：研究不依赖预定义 Schema 的开放域本体归纳技术，实现从文本中自动发现新实体类型与关系。

c. 混合知识审核：结合基于向量聚类的自动化术语对齐与基于置信度评估的人机协同（Human-in-the-loop）仲裁机制，确保图谱质量。

d. 增量更新机制：实现新旧知识的冲突检测与融合，支持图谱随新文献发表而动态演化。

（3）基于逻辑树分解与混合检索增强的问答推理方法

针对传统 RAG 技术在长链条推理中容易出现的逻辑断裂与错误累积问题，本研究将提出一种结构化的问答推理框架。

a. 递归逻辑树生成：利用大模型将复杂的多跳问题递归分解为层级化的子问题与假设（Hypothesis），构建清晰的推理逻辑树。

b. 混合检索策略：结合基于 AstroWeaver 图谱的结构化路径检索与基于文本块的语义向量检索，获取多模态证据。

c. 自适应验证与纠错：设计基于证据的假设验证机制，当检索到的事实反驳当前假设时，自动触发子树的回溯与重构，从而生成经过验证的“黄金推理树”，并据此生成最终答案。

1.4 本文的主要贡献

针对现有大语言模型在天文领域应用中面临的评测基准缺失、知识更新滞后以及复杂推理不可靠等挑战，本文开展了系统性的研究工作，提出了一套集评测、构建与推理于一体的天文智能问答技术方案。本文的主要贡献总结如下：

（1）构建了首个面向天文领域数值计算与多跳推理的评测基准 AstroRAG-600。

针对现有问答数据集侧重于通用常识或简单事实检索，缺乏对科学领域特有的数值敏感性与逻辑深度考察的问题，本文构建了包含 600 条高质量问答对的 AstroRAG-600 数据集。该数据集首次引入了“先检索后计算”（Retrieve-then-Compute）的评测模式，涵盖属性比较、隐式公式计算、多跳溯源等 5 类高阶逻辑任务。采用“自动化生成-对抗性筛选-专家级重写”的构建流水线，并提供了包含检索参数、计算公式及推理路径的白盒化证据链（Evidence Chain），为量化评估 RAG 系统的逻辑推理能力提供了精确标尺。

（2）提出了基于多智能体协同的天文知识图谱动态构建与演化框架 AstroWeaver。

针对天文文献术语多变、数据更新频繁，传统流水线式图谱构建方法存在 Schema 僵化与错误传播的问题，本文设计并实现了一个基于多智能体（Multi-Agent）协作的图谱构建系统。提出了图谱探测（Graph Probing）机制，能够不依赖预定义本体，从非结构化文本中自适应归纳实体类型与关系 Schema。设计了输入感知的异构数据聚合策略与混合智能知识审核机制（Hybrid Auditing），实现了从多源异构数据（Wikipedia、Simbad、ADS）到高质量结构化图谱的增量式更新与动态演化，有效解决了知识时效性问题。

（3）设计了基于逻辑树分解与混合检索增强的问答推理算法 TreeQA。

针对传统链式推理（Chain-of-Thought）在处理长链条科学问题时容易出现逻辑断裂与注意力迷失的问题，本文提出了一种结构化的推理框架。通过递归式逻辑树生成技术，将复杂多跳问题分解为层级化的子问题与假设，并引入结构化（图谱）与非结构化（文本）的混合检索策略。建立了基于证据的自适应验证与纠错机制，当假设被检索证据反驳时，能够自动触发推理子树的回溯与重构。实验表明，TreeQA 在 AstroRAG-600 及公开数据集 WebQSP、AdvHotPotQA 等上均取得了优于现有基线模型（如 ToG、Vanilla RAG）的准确率，并显著提升了推理过程的透明度与可信度。

1.5 论文组织结构

本文围绕面向天文领域知识增强的大语言模型问答技术展开研究，共分为六章，各章节的具体安排如下：

第一章 绪论。本章首先阐述了天文学数据密集型科研范式的转变背景，分析了大语言模型在垂直领域应用中面临的幻觉、知识滞后及推理不透明等挑战，指出了从文本检索向结构化知识推理演进的必要性。随后，介绍了本文的研究目标、主要研究内容及创新点，最后给出了论文的整体结构安排。

第二章 相关理论与技术。本章对支撑本文研究的核心理论与关键技术进行了综述。主要包括大语言模型与提示工程（Prompt Engineering）的基础理论、知识图谱的构建与推理技术、检索增强生成（RAG）的主流范式（如GraphRAG、Chain-of-Thought），以及智能体（Agent）协同技术的发展现状。同时，分析了现有技术在处理天文领域复杂问题时的局限性，为本文的研究提供理论依据。

第三章 面向天文领域的数值计算与多跳推理评测基准。本章详细介绍了AstroRAG-600 评测基准的构建过程。阐述了如何整合 Simbad 与 Wikidata 等异构数据源，设计涵盖数值计算与多跳推理的复杂逻辑模板。重点描述了基于对抗性难例挖掘的数据筛选策略，以及包含白盒化证据链的全链路标注标准，并通过统计分析验证了数据集的质量与挑战性。

第四章 基于多智能体协同的天文知识图谱动态构建与演化。本章提出了AstroWeaver 框架，旨在解决天文知识图谱的自动化构建与动态维护难题。详细设计了数据侦察员、信息提取员等多种智能体的协作机制，介绍了自适应图谱探测、混合智能知识审核以及增量式图谱更新等关键技术的实现细节。最后，通过内在质量评估与统计实验验证了该框架在构建高质量、动态演化图谱方面的有效性。

第五章 基于逻辑树分解与混合检索增强的问答推理方法。本章提出了TreeQA 推理框架，以提升大模型在复杂天文问答中的鲁棒性与可解释性。详细阐述了递归式逻辑树生成算法、结构化与非结构化的混合检索策略，以及基于证据的自适应验证与纠错机制。通过在 AstroRAG-600 及公开数据集上的对比实验与消融分析，验证了该方法在多跳推理准确率与逻辑透明度方面的优势。

第六章 总结与展望。本章对全文的研究工作进行了总结，梳理了本文在评测基准、图谱构建及推理算法方面的主要贡献。同时，客观分析了研究中存在

的局限性，如推理延迟与多模态处理能力的不足，并对未来的研究方向进行了展望。

第二章 相关理论和技术

2.1 大语言模型及其应用范式

大语言模型（Large Language Models, LLMs）代表了人工智能领域从专用模型向通用智能迈进的重要里程碑。通过在海量文本数据上进行训练，LLMs 习得了丰富的语言知识与世界知识，展现出卓越的理解、生成与推理能力。本节将深入探讨其核心架构、训练范式以及在大规模参数下涌现出的独特特性。

2.1.1 大语言模型的发展与特性

（1）Transformer 架构解析

现代大语言模型的基石是 Google 于 2017 年提出的 Transformer 架构。与传统的循环神经网络（RNN）或长短期记忆网络（LSTM）不同，Transformer 摒弃了序列递归处理的方式，完全基于注意力机制（Attention Mechanism），从而实现了高度的并行计算能力和对长距离依赖（Long-range Dependencies）的有效捕捉。

目前主流的 LLM（如 GPT 系列、LLaMA 等）大多采用 Decoder-only（仅解码器） 的 Transformer 架构。其核心组件包括多头自注意力机制（Multi-Head Self-Attention）和前馈神经网络（Position-wise Feed-Forward Networks）。

a. 缩放点积注意力机制 （Scaled Dot-Product Attention）

这是 Transformer 的核心。给定输入序列的嵌入表示 X，通过三个线性变换矩阵 W^Q,W^K,W^V 将其映射为查询（Query, Q）、键（Key, K）和值（Value, V）：

$$Q=XW^Q,K=XW^K,V=XW^V$$

注意力分数的计算公式如下：

$$\text{Attention}(Q,K,V)=\text{Softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

解释：QK^T 计算了查询与键之间的相似度（点积），用于衡量序列中不同

位置之间的相关性。$\sqrt{d_k}$ 是缩放因子（ d_k 为键向量的维度），用于防止点积结果过大导致 Softmax 函数进入梯度极小的饱和区，从而保证训练的稳定性。Softmax 将相似度归一化为概率分布（权重），最后与 V 加权求和，得到包含上下文信息的输出。

b. 多头注意力机制 （Multi-Head Attention）

为了让模型能够从不同的表示子空间（Representation Subspaces）关注信息，Transformer 将 Q,K,V 分割成 h 个头（Heads）并行计算，最后拼接：

$$\mathrm{MultiHead}(Q,K,V)=\mathrm{Concat}(\mathrm{head}_1,\ldots,\mathrm{head}_\mathrm{h})W^O$$

$$\text{where}\quad \mathrm{head}_i=\mathrm{Attention}(QW_i^Q,KW_i^K,VW_i^V)$$

解释：多头机制允许模型同时关注“语法结构”、“语义指代”、“长距离逻辑”等不同层面的特征，极大地增强了模型的表达能力。

c. 前馈神经网络 （FFN）

在每个注意力层之后，接一个全连接前馈网络，通常包含两个线性变换和一个非线性激活函数（如 ReLU 或 GeLU）：

$$\mathrm{FFN}(x)=\mathrm{Activation}(xW_1+b_1)W_2+b_2$$

（2） 预训练-微调（Pre-training & Fine-tuning）范式

LLM 的成功很大程度上归功于“预训练-微调”这一两阶段范式。

a. 预训练阶段 （Pre-training）

预训练旨在利用海量无标注文本数据（如 Common Crawl, Wikipedia, 代码库等），通过自监督学习（Self-Supervised Learning）让模型习得通用的语言模式和世界知识。对于生成式 LLM，最常用的目标函数是因果语言建模（Causal Language Modeling, CLM），即根据上文预测下一个 Token。

假设训练语料库为 U，模型参数为 Θ，预训练的目标是最大化似然函数：

$$U=\{u_1,u_2,\ldots,u_n\}$$

$$\mathscr{L}_{\mathrm{PT}}(\Theta)=\sum_i \log P(u_i|u_{i-k},\ldots,u_{i-1};\Theta)$$

解释：k 为上下文窗口大小。该公式表明模型通过最小化预测下一个词的负对数似然（Negative Log-Likelihood）来更新参数 Θ。这一过程极其消耗算力，但赋予了模型广泛的通用知识。

b. 微调阶段（Fine-tuning）

预训练后的模型虽然具备生成能力，但往往难以直接遵循人类指令或完成特定任务。微调阶段通过在特定任务的有标注数据集上进行有监督训练，调整模型参数以适配下游任务。

假设有标注数据集 $D=\{(x_1,y_1),\ldots,(x_m,y_m)\}$，其中 x 为输入（Prompt），y 为期望输出，微调的目标函数为：

$$\mathscr{L}_{\mathrm{FT}}(\Theta)=\sum_{(x,y)\in D}\log P(y|x;\Theta)$$

指令微调（Instruction Tuning）：近年来，微调范式进一步演变为指令微调，即使用多样化的任务指令数据进行训练，使模型能够泛化到未见过的指令任务中。

人类反馈强化学习（RLHF）：为了使模型输出更符合人类价值观（有用性、诚实性、无害性），通常还会引入 RLHF，通过奖励模型（Reward Model）对生成结果打分，并使用 PPO 算法优化策略。

（3）LLM 的涌现能力（Emergent Abilities）

当语言模型的参数规模（Scale）和训练数据量超过某个临界阈值（通常认为在 10^{22} FLOPs 训练计算量或百亿参数级以上）时，模型会表现出一些在小模型中不存在的、意料之外的能力，这种现象被称为涌现能力。主要涌现能力分析：

a. 上下文学习（In-Context Learning, ICL）：模型无需更新权重，仅通过在 Prompt 中提供少量的示例（Few-shot），就能理解任务意图并输出正确结果。公式化描述：给定示例集 $C=\{(x_1,y_1),\ldots,(x_k,y_k)\}$和测试输入 x_{test}，模型直接推断 $P(y_{test}|C,x_{test};\Theta)$，表现出类比推理能力。

b. 思维链推理（Chain-of-Thought, CoT）：当要求模型在给出最终答案前先生成推理步骤（"Let's think step by step"）时，LLM 处理复杂逻辑、数学问题和常识推理的能力显著提升。原理：CoT 将一个复杂的 P（y|x） 映射分解为一系列中间步骤 $P(z_1|x)\cdot P(z_2|x,z_1)\ldots P(y|x,z_{1\ldots n})$，降低了单步推理的难度，利用了 Transformer 强大的序列生成能力来模拟逻辑推导过程。

（4）在科学领域的应用潜力（AI for Science）

LLM 的涌现能力为其在科学研究中的应用提供了广阔前景，正在改变传统

的科研范式：

跨学科知识整合与假设生成：科学文献浩如烟海，人类专家难以穷尽。LLM 可以作为“超级阅读器”，通过处理数百万篇论文，发现不同学科间潜在的关联（例如，某种物理结构与生物蛋白折叠的相似性），从而辅助科学家提出新的研究假设。

代码生成与计算模拟：在计算物理、生物信息学等领域，LLM 能够根据自然语言描述生成复杂的仿真代码（如 Python, MATLAB 脚本），甚至辅助编写涉及偏微分方程求解的数值计算程序，大幅降低科研门槛。

复杂系统推理：利用 CoT 能力，LLM 可以辅助分析复杂的化学反应路径或基因调控网络。虽然它不能替代严谨的实验验证，但可以作为高效的“推理引擎”筛选高可能性的实验路径，缩短研发周期。

多模态科学数据分析：结合多模态技术，LLM 正在向处理分子图谱、天文图像等非文本数据扩展，成为连接科学数据与自然语言解释的桥梁。

2.1.2 提示工程（Prompt Engineering）

提示工程（Prompt Engineering）是指通过设计、优化和精炼输入给大语言模型（LLM）的文本提示（Prompt），以引导模型生成准确、相关且符合预期格式的输出的技术。作为一种无需更新模型参数即可提升任务表现的手段，提示工程已成为开发基于 LLM 应用的核心能力，其本质是利用自然语言作为编程接口，挖掘模型在预训练阶段习得的潜在知识与推理能力。

（1） 基础提示范式

提示工程的基础方法主要依赖于模型对上下文的理解能力，其中最具代表性的范式包括零样本提示（Zero-shot Prompting）和少样本提示（Few-shot Prompting）。

a. 零样本提示（Zero-shot Prompting）

零样本提示是指在不提供任何具体示例的情况下，直接向模型下达指令并期望其完成任务。这种方法完全依赖于模型在预训练阶段通过海量数据习得的泛化能力和对指令的理解能力。

示例：*“将以下句子翻译成法语：‘今天天气真好。’”*

特点： 简便快捷，适用于常见的一般性任务（如翻译、摘要），但在处理复杂

逻辑或特定领域任务时，效果可能不如预期。

b. 少样本提示（Few-shot Prompting）

少样本提示利用了模型的上下文学习（In-Context Learning, ICL）能力。通过在提示词中提供少量（通常为 1 到 5 个）输入与理想输出的示例（Demonstrations），引导模型识别任务模式并模仿示例的逻辑进行推理。

示例：

“任务：判断影评的情感倾向（正面/负面）。

例子 1：这部电影简直是浪费时间。 -> 负面

例子 2：演员的演技令人惊叹，剧本也很扎实。 -> 正面

例子 3：虽然特效不错，但剧情逻辑混乱。-> ？”

特点： 显著提升了模型在复杂任务、特定风格模仿及生僻领域中的表现，能够有效修正模型的输出偏差。

（2）指令遵循与特定场景引导

除了提升推理准确性，提示工程在规范模型行为、对接下游应用接口方面发挥着至关重要的作用。通过精细设计的指令，可以强制模型遵循特定的输出约束。

a. 结构化输出引导（JSON/XML 格式化）

在工程应用中，LLM 的输出通常需要被代码解析。自然语言的随意性是系统集成的最大障碍。提示工程通过明确的格式约束指令，强制模型输出机器可读的数据结构（如 JSON）。

实现策略：在提示中明确定义 Schema（数据模式）或提供 JSON 示例模板。

示例指令：*“请从上述文本中提取用户信息，并严输出为 JSON 格式，包含键值 name （string） 和 age （int）。不要包含任何 Markdown 标记或解释性文字。”*

作用： 极大地提高了 LLM 与传统软件系统集成的稳定性，减少了正则表达式解析的失败率。

b. 角色扮演与风格设定（Role-playing）

通过设定“系统角色”（System Role）或使用“假设你是...”的句式，可以将模型限定在特定的语境、知识域或情感基调中。这种技术改变了模型生成文本

的概率分布，使其更倾向于该角色应有的词汇和逻辑。

实现策略： 在对话开始前设定 System Prompt（系统提示词）。

示例指令：“*你是一位拥有 20 年经验的资深 Python 架构师。请以专业、简洁且略带批判性的口吻评审以下代码...*”

作用： 能够显著提升特定领域（如法律、医疗、编程）回答的专业度，或在聊天机器人场景中提供更具沉浸感的用户体验。

2.1.3 大模型的局限性分析

尽管大语言模型在自然语言处理任务中展现出了惊人的泛化能力，但其本质上仍是一个基于统计概率的预测系统，而非具备真实认知能力的智能体。这种底层架构决定了模型在实际应用中存在不可忽视的内生缺陷，其中最为棘手且普遍的现象便是“幻觉”（Hallucination）。

幻觉现象并非简单的逻辑错误，而是模型训练机制的直接产物。知名科幻作家特德·姜（Ted Chiang）曾将大模型比作“互联网的模糊 JPEG”，这一隐喻精准地揭示了幻觉的成因——有损数据压缩。在预训练阶段，模型试图将海量文本数据压缩进有限的参数空间中，这一过程不可避免地伴随着信息的丢失与模糊化；当模型在推理阶段试图“解压”并复述某些具体事实时，如果相关记忆不够清晰，它便会转向概率预测机制。此时，模型不再是基于事实进行检索，而是根据上下文统计规律，生成在语法和逻辑上看似合理、实则完全虚构的内容。这种“幻觉”现象，在处理法律条文引用或医疗诊断等高精度要求任务时，构成了极大的安全隐患。

除了准确性的挑战，模型在知识的时效性与覆盖面上也面临着严峻的物理瓶颈。由于预训练过程需要消耗巨大的算力与时间成本，模型一旦训练完成，其参数即被冻结，导致了知识截止（Knowledge Cutoff） 问题的出现。一个训练截止于 2023 年的模型，对于随后发生的国际事件或新发布的技术框架一无所知，这使得单纯依赖模型参数无法满足实时性要求高的应用场景。

更为隐蔽的局限在于长尾知识的遗忘。模型在优化过程中倾向于拟合训练语料中高频出现的通用知识（如世界历史、流行编程语言），而对于那些在语料中出现频率极低、但对特定领域至关重要的长尾知识（如企业内部文档、罕见病理特征），模型往往难以形成稳固的记忆，甚至会在训练后期发生灾难性

遗忘。

正是由于大模型自身存在的幻觉风险、时效滞后以及长尾知识匮乏，单纯依靠模型内部的参数记忆已无法满足垂直领域对精准度与实时性的双重需求。这一现状迫使研究者将目光投向模型外部，试图通过引入外部知识库来弥补模型参数的不足，从而直接催生了检索增强生成（RAG）与知识图谱（KG）融合等技术的兴起与发展。

2.2 知识图谱构建与存储技术

2.2.1 知识图谱的基本概念

知识图谱（Knowledge Graph, KG）本质上是一种大规模语义网络，它试图将人类认知世界中的万物及其关联，映射为计算机可理解的结构化数据形式。不同于传统关系型数据库的行列存储，知识图谱以图论为数学基础，其核心构建单元由实体（Entity）、关系（Relation）与属性（Attribute）共同编织而成。

在这个语义网络中，实体构成了图的节点，代表现实世界中独立存在的对象，如具体的人物“爱因斯坦”、抽象的概念“相对论”或特定的机构“普林斯顿大学”；关系则是连接节点的边，刻画了实体之间存在的某种客观联系，例如“提出”、“任教于”等，正是这些关系赋予了孤立数据以语义背景；而属性则作为依附于实体或关系的键值对，用于描述对象的具体特征，如爱因斯坦的“出生日期”或相对论的“提出时间”。这三者最终被形式化为三元组（Triplet）表示法，即（h,r,t），其中 h 代表头实体， r 代表关系， t 代表尾实体。这种简洁而强大的结构（例如：<爱因斯坦,提出,相对论>），使得复杂的非结构化信息得以被转化为机器可推理的逻辑网络。

然而，理论上的图结构若要落地为高效的查询系统，必须依赖底层的物理存储技术支持。

对于显式的三元组结构，图数据库（Graph Database）——以 Neo4j 为典型代表——提供了原生的存储支持。与传统数据库依赖昂贵的表连接（JOIN）操作不同，Neo4j 采用了“免索引邻接”（Index-free Adjacency）机制，即每个节点直接存储指向其邻居节点的物理地址。这种设计使得在进行多跳（Multi-hop）查询或路径探索时，系统能够以接近 O（1）的时间复杂度遍历关系网络，极大

地提升了复杂关联分析的效率，为基于规则的推理提供了坚实的物理基础。

与此同时，为了捕捉实体和文本中隐含的语义特征，向量数据库（Vector Database）则扮演了不可或缺的角色。在 传统 RAG 系统的存储层设计中，文本数据经过 Embedding 模型处理后，被转化为高维空间中的稠密向量。向量数据库专门针对这些高维向量进行了索引优化（如 HNSW 算法），允许系统通过计算余弦相似度或欧氏距离，快速检索出语义上相近的内容，即便这些内容在字面上完全不同。

这种将图数据库的结构化关联能力与向量数据库的语义模糊匹配能力相结合的策略，不仅解决了单一存储模态的局限性，更为后续的检索增强生成（RAG）提供了兼具精确逻辑与广泛语义的混合索引支持。

2.2.2 信息抽取技术（Information Extraction, IE）

若将知识图谱比作一座大厦，那么信息抽取（IE）便是从非结构化文本的矿山中提炼建筑材料——实体与关系——的核心工艺。这一过程主要包含两个紧密耦合的子任务：命名实体识别（NER）与关系抽取（RE）。

在深度学习早期的技术范式中，这两项任务通常被设计为串行的流水线（Pipeline）架构：系统先识别出文本中的实体边界与类型（如人名、地名），再对实体对进行分类以确定其关系。然而，这种割裂的处理方式存在显著的“级联错误”风险——一旦上游的实体识别出现偏差，下游的关系抽取便无从谈起，且模型往往难以捕捉实体与关系之间潜在的语义依赖。随着大语言模型（LLM）的崛起，基于联合抽取（Joint Extraction）的范式逐渐成为主流。得益于 LLM 强大的上下文感知能力与指令遵循能力，研究者现在可以通过精心设计的 Prompt，引导模型在一个推理步骤中同时输出实体及其对应的关系三元组。这种端到端的方法不仅有效规避了误差累积，还能利用模型内部的先验知识，解决传统模型难以处理的重叠关系或跨句推理问题。

然而，无论是传统的流水线还是基于 LLM 的联合抽取，通常都依赖于预定义的 Schema（模式），即需要预先设定好“人-出生地-地点”或“公司-收购-公司”等固定的关系类型。这种封闭域的设定虽然保证了数据的规范性，却难以适应互联网海量且多变的文本场景。

为了突破预定义模式的束缚，开放域信息抽取（OpenIE）应运而生。

OpenIE 不再依赖人工设定的关系集合，而是直接利用文本中的自然语言短语（通常是动词短语）作为关系描述，从句子中抽取形如($Argument_1$,$Relation$,$Argument_2$)的结构化信息。例如，面对句子“深度学习显著提升了图像识别的准确率”，OpenIE 能够直接提取出<深度学习,显著提升了,图像识别的准确率>，而无需预先定义“提升”这一关系类别。这种范式极大地扩展了知识获取的广度，使其能够快速适应新兴领域或长尾知识的构建需求，尽管其代价是提取出的关系往往缺乏标准化，需要后续的实体对齐与消歧处理来提升图谱质量。

总体而言，从依赖 Schema 的精确抽取到拥抱开放域的广泛抽取，信息抽取技术的演进正是为了在准确性与覆盖率之间寻找最佳平衡，从而为知识图谱的构建提供源源不断的高质量数据养分。

2.2.3 知识融合与消歧

从多源异构数据中抽取出的原始三元组，往往如同散落且未经打磨的拼图碎片，存在着大量的冗余、冲突以及指代不明的现象。要将这些碎片拼凑成一张逻辑严密、语义连贯的知识网络，必须经过知识融合与消歧的精细化处理，其中实体对齐（Entity Alignment）与指代消解（Coreference Resolution）是提升图谱质量的关键环节。

在多源知识库的构建过程中，同一现实世界对象在不同数据源中往往拥有截然不同的标识或描述。例如，“IBM”、“国际商业机器公司”与“Big Blue”虽然字面差异巨大，但在语义空间中均指向同一个企业实体。实体对齐的任务正是要识别并合并这些等价节点，从而消除数据冗余并整合互补属性。早期的对齐方法主要依赖于字符串相似度（如 Levenshtein 距离）或基于属性的规则匹配，但在面对跨语言或非规范化文本时显得力不从心。近年来，基于表示学习（Representation Learning）的方法逐渐占据主导地位，通过 TransE、GCN（图卷积网络）等模型将实体映射为低维稠密向量，利用向量空间中的几何距离来度量实体间的语义相似度。这种方法不仅能够捕捉实体的字面特征，更能利用图结构中的邻域信息，显著提升了对齐的鲁棒性。

如果说实体对齐解决的是跨库的“多名一物”问题，那么指代消解则致力于解决篇章内部的“代词模糊”问题。在自然语言文本中，为了表达的简洁性，作

者大量使用代词（如“他”、“其”、“该公司”）或名词短语（如“这位科学家”）来指代前文出现过的实体。若不进行消解，机器抽取的将是形如<他,发布了,新产品>这样缺乏具体指涉、无法用于推理的无效三元组。指代消解技术通过分析文本的上下文依赖关系，将这些指代词（Mentions）链接到其对应的具体实体（Entities）上。随着深度学习的发展，该领域已从传统的基于规则和聚类的方法，演进为基于端到端神经网络的模型，特别是大语言模型的引入，使得系统能够跨越长距离的文本跨度，精准捕捉复杂的指代逻辑，从而确保抽取的知识在脱离原始语境后依然具备独立且完整的语义价值。

通过实体对齐实现知识的横向整合，利用指代消解完成语义的纵向贯通，这两个过程共同构成了知识图谱构建中的“清洗与精炼”工序，直接决定了最终图谱的稠密度与推理的可信度。

2.3 检索增强生成（RAG）技术

2.3.1 RAG 的基本架构

检索增强生成（RAG）技术通过引入外部知识库，打破了模型参数记忆的物理边界，其核心运作机制可以被视为一个从数据预处理到语义合成的有机闭环。这一标准架构主要由索引（Indexing）、检索（Retrieval）与生成（Generation）三个紧密耦合的阶段构成，共同实现将静态的外部知识转化为动态的智能回答。

这一架构的基石在于索引（Indexing）阶段，其本质是将非结构化的原始数据转化为机器可高效查询的语义表征。在这一过程中，海量的文档首先被分割为长度适中的文本块（Chunks），以适应模型的上下文窗口限制并保留语义的完整性。随后，利用预训练的 Embedding 模型，这些文本块被映射为高维空间中的稠密向量。不同于传统的关键词索引，这种向量化存储捕捉了文本深层的语义特征，使得“苹果”与“水果”在数学空间中彼此邻近，从而为后续的模糊匹配奠定了物理基础。

当用户发起交互时，系统即刻进入检索（Retrieval）阶段。用户的自然语言查询首先经过与索引阶段相同的编码器处理，转化为查询向量。系统随即在向量数据库中执行相似度计算（如余弦相似度），在海量的知识向量中快速定

位并召回与查询语义最接近的 Top-K 个文本块。这一过程类似于在图书馆中根据书的内容而非书名进行快速定位，确保了即使查询词汇与文档原文不完全一致，系统依然能够精准捕获相关的背景知识。

最终的生成（Generation）阶段则是逻辑闭环的关键，它负责将检索到的碎片化信息整合成连贯的自然语言回复。系统将检索到的高相关性文本块作为“上下文（Context）”，与用户的原始问题共同组装成一个增强后的提示词（Prompt）。大语言模型（LLM）在接收到这一包含丰富背景信息的输入后，不再单纯依赖内部的参数记忆进行概率预测，而是转变为“阅读理解”模式，基于提供的上下文进行事实性的归纳与推理。这种“开卷考试”般的生成机制，不仅显著降低了模型产生幻觉的风险，更使得生成的回答能够精准覆盖最新的数据与特定的领域知识。

2.3.2 文本检索与向量相似度

在信息检索技术的演进历程中，稠密检索（Dense Retrieval） 的出现标志着从基于关键词的字面匹配向基于向量的语义匹配的范式转变。不同于传统 BM25 算法依赖稀疏的高维词袋模型，稠密检索利用深度神经网络（如 BERT 等双编码器架构），将查询（Query）与文档（Document）映射到同一个低维连续的向量空间（$\mathbb{R}^d$）中。在这个空间内，文本的相关性不再取决于词汇的重叠程度，而是由向量在几何空间中的接近程度来衡量。

为了量化这种语义上的接近度，系统通常采用余弦相似度（Cosine Similarity）作为核心度量标准。假设查询向量为 $\vec{q}$，文档向量为 $\vec{d}$，两者之间的相关性得分 $S(\vec{q},\vec{d})$ 可通过计算两个向量夹角的余弦值来确定：

$$S(\vec{q},\vec{d})=\frac{\vec{q}\cdot\vec{d}}{//\vec{q}//\,//\vec{d}//}=\frac{\sum_{i=1}^{n}q_i d_i}{\sqrt{\sum_{i=1}^{n}q_i^2}\sqrt{\sum_{i=1}^{n}d_i^2}}$$

通过这一数学形式的转化，稠密检索展现出了处理语义匹配的显著优势。它能够有效解决“词汇失配（Vocabulary Mismatch）”问题，即当用户查询词与文档关键词不一致但意图相同时（例如用户搜索“无线网络故障”，而文档中仅

包含“Wi-Fi 连接中断”），传统方法往往无能为力，而稠密检索因其向量在空间中的邻近性，依然能够精准召回相关内容。这种泛化能力使得系统能够理解同义词、多义词以及隐含的上下文逻辑。

然而，这种将离散的符号映射为连续向量的过程，本质上是一种有损压缩，这导致稠密检索在处理精确匹配任务时存在天然的短板。当查询涉及特定的专有名词、序列号、代码片段或极低频的实体（如区分“iPhone 15”与“iPhone 16”，或检索特定的错误代码“0x80040115”）时，Embedding 模型往往难以捕捉这些细微的字符级差异，容易检索到语义相似但细节错误的“幻觉”文档。因此，在实际的工程应用中，单纯依赖稠密检索往往难以满足所有场景，通常需要结合基于倒排索引的关键词检索，以互补的方式平衡语义理解的广度与字符匹配的精度。

2.3.3 基于图谱的检索增强（GraphRAG）

尽管传统的基于向量的 RAG 技术在处理语义相似性匹配上表现出色，但在面对需要深度推理或跨文档关联的复杂查询时，其局限性便暴露无遗。这种局限主要源于向量检索底层的“切片”机制——为了适应 Embedding 模型，长文档被机械地切割为独立的文本块（Chunks）。这一过程虽然保留了局部的语义特征，却无情地切断了概念之间原本存在的全局逻辑联系，导致模型在面对分散于不同文档中的关联信息时，往往陷入“只见树木，不见森林”的碎片化陷阱。

GraphRAG 正是为了填补这一逻辑鸿沟而生。与仅依赖概率距离的向量检索不同，GraphRAG 将检索的颗粒度从非结构化的文本块提升到了结构化的知识图谱层面。在这种架构下，实体不再是孤立的向量点，而是通过显式的关系边（Edges）相互锚定，形成了一张严密的语义网络。这种结构化关联的优势在于，它能够捕捉并固化那些在字面上距离遥远、但在逻辑上紧密相连的信息。例如，在分析金融风险时，一家子公司的违约事件与母公司的股价波动可能分布在两份完全不同的报告中，传统的向量检索极易因缺乏关键词重叠而忽略二者的联系，而 GraphRAG 则能顺着“子公司-隶属于-母公司”的图谱路径，将这两个孤立的事实强关联起来，为模型提供完整的上下文视野。

更为重要的是，GraphRAG 赋予了系统执行多跳路径检索（Multi-hop

Retrieval）的能力，这是解决复杂推理问题的关键所在。在实际的研究场景中，用户的提问往往隐含着多层逻辑嵌套，如“导致 A 事件发生的那个原因，对 B 产生了什么影响？”这类问题要求系统不仅要找到 A 和 B，更要复原它们之间的因果链条。传统 RAG 往往只能分别检索到 A 和 B 的片段，却无法拼凑出中间的桥梁；而 GraphRAG 利用图数据库的遍历算法，能够像人类推理一样，沿着图谱中的关系路径 A←原因→影响→B 进行多步跳跃。这种检索方式不再是简单的“大海捞针”，而是沿着逻辑线索“顺藤摸瓜”，从而能够精准地聚合分散的证据链，显著提升了模型在回答开放式、综合性问题时的逻辑深度与可解释性。

因此，GraphRAG 并非是对传统 RAG 的全盘否定，而是一种维度的升维——它将检索的视角从扁平的文本相似度拓展到了立体的逻辑连通性，从而让大模型不仅能“读懂”文字，更能“看清”事物背后错综复杂的关系脉络。

2.4 复杂推理与智能体协同技术

2.4.1 思维链（Chain-of-Thought, CoT）及其变体

大语言模型在处理直觉性任务时往往表现出色，但在面对需要多步逻辑推演的复杂问题时，直接生成答案的“快思考”模式容易导致推理断层或计算错误。为了激发模型的“慢思考”能力，思维链（Chain-of-Thought, CoT） 技术应运而生。其核心思想在于打破模型“输入即输出”的黑盒映射，通过在提示中显式地要求模型生成一系列中间推理步骤（Intermediate Reasoning Steps），将一个庞大的复杂问题拆解为若干个可管理的子问题。这种线性分解不仅让模型的推理过程变得可解释，更重要的是，它利用了模型自回归生成的特性，让前一步的推理结果作为后一步的上下文输入，从而显著提升了逻辑的一致性与准确性。

尽管 CoT 及其变体在处理线性逻辑任务上成效显著，但在面对需要探索、规划或具有多种可能解空间的开放性问题时，单向线性的推理路径显得过于僵化——一旦中间某一步走错，整个推理便无法挽回。为了突破这一拓扑限制，思维树（Tree of Thoughts, ToT） 引入了更为高阶的非线性推理框架。ToT 将大模型的推理过程建模为一棵搜索树，其中每一个节点代表一个中间思维状态

（Thought）。与 CoT 一条路走到黑不同，ToT 允许模型在每一个决策点生成多个可能的下一步（分支），并利用模型自身的评估能力对这些分支的前景进行打分或投票。

这种树状结构赋予了模型类似人类解决难题时的搜索与回溯（Search and Backtracking） 能力。在实际运行中，ToT 通常结合广度优先搜索（BFS）或深度优先搜索（DFS）算法：当模型发现当前分支的评估得分过低或逻辑陷入死胡同时，它能够主动放弃该路径，回溯到上一个父节点，重新选择更有希望的分支继续探索。这种机制本质上是将经典的启发式搜索算法与大模型的生成能力相结合，使得模型在处理创意写作、代码生成或复杂数学证明等任务时，能够进行全局规划与局部试错，从而在巨大的解空间中寻找到最优解。

2.4.2 智能体（AI Agents）与多智能体系统

如果说大语言模型（LLM）是存储了海量知识的静态“大脑”，那么智能体（AI Agents）则是为其装上了感知世界的“五官”与改变环境的“手脚”。智能体的核心突破在于将 LLM 从被动的文本生成器转变为主动的问题解决者，其运作机制不再局限于单一的输入输出映射，而是构建了一个包含感知（Perception）、规划（Planning）与行动（Action）的动态闭环。

在这一闭环中，ReAct（Reasoning + Acting） 范式扮演着至关重要的角色。不同于传统的问答模式，ReAct 要求模型在执行任务时，交替进行内部的逻辑推理（Reasoning）与外部的工具调用（Acting）。例如，当面对“查询某上市公司最新财报并分析其同比增长率”这一指令时，智能体不会直接编造数据，而是先规划出“搜索财报”、“读取数据”、“计算增长率”的步骤，随后调用搜索引擎或数据库接口获取真实信息，并根据返回的观察结果（Observation）修正后续的推理路径。这种“思考-行动-观察”的循环机制，使得智能体能够通过与环境的交互来弥补模型内部知识的滞后性，极大地提升了任务执行的落地能力。

然而，正如个体智力在处理超大规模复杂系统时存在认知负荷的上限，单一智能体在面对长链路、多维度的综合性任务时，也往往会陷入上下文迷失或指令冲突的困境。试图让一个智能体同时扮演“程序员”、“测试员”和“产品经理”的角色，极易导致其注意力分散，进而产生逻辑混乱。为了突破这一瓶颈，多智能体协作（Multi-Agent Collaboration） 模式应运而生，其核心理念在于模拟

人类社会的组织分工——“术业有专攻”。

在多智能体系统中，复杂的任务被解构并分配给具有不同角色设定（Role-playing）的独立智能体。通过提示工程，这些智能体被赋予了特定的性格、技能树与权限边界：有的专注于广度信息的检索（Researcher），有的擅长代码的生成与优化（Coder），有的则负责以批判性的眼光审查输出质量（Reviewer）。这些角色之间并非孤立工作，而是通过预定义的交互机制（如顺序传递、辩论协商或投票决策）进行深度的信息交换。这种协作模式不仅通过角色分工扩展了系统的整体上下文窗口，更重要的是，通过引入不同视角的“对抗”与“校验”，系统能够实现自我纠错，显著降低了单点故障与幻觉风险。

2.5 问答系统评估方法

2.5.1 主流问答数据集综述

构建高质量的问答系统离不开基准数据集的磨砺与验证。在通用知识领域，学术界已经积累了诸如 WebQSP 和 ComplexWebQuestions 等经典数据集。WebQSP 基于 Freebase 知识库构建，主要关注事实性问题的单跳或简单多跳检索，是检验系统基础实体链接能力的标准测试集；而 ComplexWebQuestions 则通过组合多个简单问题或引入时间、比较等约束条件，显著提升了问题的语义复杂度，旨在测试系统在面对长难句时的分解与推理能力。这些数据集为通用问答技术的发展提供了标准化的跑道，推动了从语义解析到端到端模型的迭代。

然而，当我们将目光投向对精度要求极高的科学领域，尤其是天文学领域时，现有的通用数据集便显得捉襟见肘。科学探索往往涉及复杂的数值计算（如天体距离换算、轨道参数推导）与深度的因果推理（如恒星演化阶段的判定），而通用数据集中的问题大多停留在浅层的实体属性查询层面，缺乏对物理定律应用与定量分析的考察。此外，天文学知识具有极强的长尾效应与时效性，新发现的系外行星或瞬变天体往往无法及时反映在基于旧版百科构建的数据集中。这种评测数据在深度与广度上的双重匮乏，导致现有的评估体系难以真实反映大模型在垂直科研场景下的实际效能，迫切需要构建专注于科学逻辑与数值推理的专用评测基准。

2.5.2 评估指标

与数据集的演进相呼应，问答系统的评估指标也经历了从机械匹配到语义审视的变革。在早期的抽取式问答任务中，精确匹配（Exact Match, EM） 与 F1 分数 是占据统治地位的黄金标准。EM 指标苛刻地要求预测答案与标准答案在字符级别上完全一致，这对于实体类问题（如“木星有多少颗卫星”）尚且适用，但在面对生成式长文本时显得过于僵化；F1 分数虽然通过计算词汇重叠率引入了一定的容错空间，但其本质上仍是基于字面形式的统计，无法捕捉同义表达或句式变换背后的语义一致性。例如，模型回答“距离地球约 4 光年”与标准答案“4.2 光年”在 F1 上得分可能很高，但在科学严谨性上却是错误的；反之，意思相同但措辞迥异的回答则可能被误判为低分。

为了突破传统指标在语义理解上的局限，基于模型的评估（LLM-as-a-Judge） 逐渐成为生成式问答评估的新范式。该方法利用 GPT-4 等强力大模型作为“裁判”，通过精心设计的 Prompt，引导模型从准确性、完整性、逻辑连贯性等多个维度对生成的答案进行打分或排序。这种方法模拟了人类专家的评估过程，不仅能够识别“虽然字面不同但语义正确”的回答，还能敏锐地捕捉到传统指标难以发现的逻辑矛盾或幻觉细节。特别是在长文本生成评估中，LLM-as-a-Judge 展现出了极高的人类一致性，为评估那些没有唯一标准答案的开放性科学问题提供了一种可扩展且相对客观的自动化解决方案。

2.6 本章小结

本章围绕支撑天文智能问答的核心理论与关键技术展开了系统梳理，旨在为后续的垂直领域技术构建厘清理论边界与改进方向。

尽管以 Transformer 为基石的大语言模型在通用自然语言处理任务中展现了惊人的泛化能力，但当我们将其置于天文学这一对数值精度与逻辑严密性有着苛刻要求的“硬科学”场景下审视时，模型内生的概率预测机制所导致的“数值幻觉”与长尾知识遗忘问题便暴露无遗。这种单纯依赖参数记忆的局限性，迫使研究重心从模型内部转向了外部知识增强技术。

为突破这一记忆瓶颈，检索增强生成（RAG）与知识图谱（KG）技术应运而生。然而，通过对比分析基于向量的非结构化检索与基于图谱的结构化检

索，我们发现传统的向量检索在处理跨文档的多跳推理时，往往难以跨越“语义相似”与“逻辑相关”之间的鸿沟；而知识图谱虽然能够提供显式的推理路径，但在面对海量且高速更新的天文文献时，其自动化构建与动态维护仍面临着巨大的技术挑战。与此同时，从思维链（CoT）到多智能体（Multi-Agent）协同的演进，虽然为解决复杂问题提供了新的范式，但现有的通用架构在缺乏领域特有约束（如物理公式验证）的情况下，仍难以保证推理结果的科学可信度。

更为关键的是，现有评测体系多聚焦于通用常识或简单的实体检索，缺乏对科学领域特有的数值计算与证据链完整性的深度考察，这使得大模型在垂直领域的真实能力难以被量化评估。正是基于对上述技术断点与评测空白的深刻洞察，构建一套专属于天文领域的复杂推理评测基准显得尤为迫切。下一章将详细阐述 AstroRAG-600 评测基准的构建过程，通过引入对抗性难例挖掘与白盒化证据链设计，为后续的图谱构建与推理算法研究提供一把精确的量化标尺。

第三章 面向天文领域的数值计算与多跳推理评测基准

天文学作为一门建立在精确观测与严谨物理定律之上的“硬科学”，其研究范式正经历着从定性描述向定量分析的深刻转变。在这种数据密集型的科研背景下，科研人员对智能问答系统的期待早已超越了简单的“事实查证”，转而聚焦于更深层次的数值推理与逻辑演绎。然而，当我们审视现有的检索增强生成（RAG）技术评测体系时，不难发现一个明显的错位：主流评测基准（如 WebQSP, Natural Questions 或 TruthfulQA）大多侧重于通用领域的常识性问答或单一文档的信息抽取，这种基于语义匹配的浅层考察，难以触及垂直科学领域中最为核心的“数值敏感性”与“逻辑完备性”问题。

在实际的天文科研场景中，一个看似简单的问题往往隐含着极高的推理复杂度。例如，当研究者询问“计算距离地球最近的红超巨星的切向速度”时，大语言模型无法指望在某篇现成的文献中直接检索到最终答案。相反，系统必须执行一套被称为“先检索后计算”（Retrieve-then-Compute）的复杂认知流程：它需要首先通过知识图谱识别出符合“红超巨星”且“距离最近”的实体（如参宿四），接着从星表数据库中分别检索其“自行”（Proper Motion）与“视差”（Parallax）等离散参数，最后调用特定的物理公式进行精确的数值运算。这种跨越非结构化文本与结构化数据的多跳推理过程，正是当前通用大模型在科学领域落地的最大瓶颈所在。

更为棘手的是，大语言模型固有的“概率生成”特性在处理此类精确问题时，极易陷入参数化记忆（Parametric Memory）的陷阱。我们在前期的实验观察中发现，对于太阳、天狼星等热门天体，模型往往倾向于直接输出预训练阶段“记住”的数值，而非基于检索到的最新观测数据进行回答。这种依赖内部记忆的机制不仅导致了严重的幻觉问题，即模型会以极高的置信度编造出一个看似合理实则错误的数值，更掩盖了 RAG 系统在检索与推理环节的真实缺陷。为了剥离模型内部记忆的干扰，真正评估其利用外部知识解决未知问题的能力，构建一个包含大量长尾天体、且必须依赖外部证据链才能解答的“对抗性”评测基准显得尤为迫切。

正是基于对上述挑战的深刻洞察，本章将详细阐述 AstroRAG-600 评测基准的构建逻辑与实现细节。不同于以往仅关注文本相似度的评测集，AstroRAG-600 旨在建立一套涵盖数值计算、属性比较及多跳溯源的综合评价体系，通过引入“白盒化”的证据链标注与严格的对抗性难例挖掘，为量化评估大模型在天文垂直领域的复杂推理能力提供一把标尺。

3.1 异构数据源整合与预处理

构建一个能够真实反映科研级推理难度的评测基准，其首要前提是拥有高质量、高精度且具备逻辑关联的底层数据。然而，天文学领域的数据现状呈现出典型的高度异构特征：一方面是海量且精确的观测数值，它们往往以半结构化的形式散落在各类专业星表中；另一方面则是复杂的实体关系与背景知识，通常以图谱或文本的形式存在。为了打破这种数据模态的壁垒，本研究选取了 Simbad 与 Wikidata 作为两大核心数据源，并通过定制化的解析与清洗流程，完成了从“原始数据孤岛”到“结构化推理语料”的整合。

3.1.1 高精度观测数据：Simbad 数据库的半结构化解析与数值标准化

作为天文学界最权威的深空天体数据库之一，Simbad（由斯特拉斯堡天文数据中心 CDS 维护）虽然汇集了数百万天体的详尽观测记录，但其数据呈现方式主要服务于人类专家的查阅习惯，而非机器的自动化处理。我们在数据探查中发现，Simbad 的原始输出多为半结构化的 ASCII 文本或表格，其中数值字段往往混杂着非标准的注释符号（如代表近似值的 ~、代表上下限的 < >）以及不统一的计量单位。这种格式上的“噪音”对于依赖精确浮点数运算的 RAG 系统而言，构成了致命的干扰。

针对这一问题，我们开发了一套专用的 Python 解析器，对 Simbad 中的关键物理参数进行了深度清洗与标准化处理。重点提取的字段涵盖了恒星的基本属性（如视星等 Flux V/B/J/H/K、光谱类型 Spectral Type）以及用于动力学计算的核心参数（如视差 Parallax、自行 Proper Motion、径向速度 Radial Velocity 和红移 Redshift）。在处理过程中，解析器不仅剔除了所有非数值的特殊符号，还将不同来源的单位统一转换为标准国际单位制（例如将自行单位统一为

mas/yr），从而确保了后续“先检索后计算”任务中数值输入的唯一性与准确性。

3.1.2 结构化知识图谱：Wikidata 的 SPARQL 查询模板设计与多跳路径提取

如果说 Simbad 提供了天体的“物理骨肉”，那么 Wikidata 则构成了连接这些孤立实体的“逻辑经络”。为了构建具有挑战性的多跳推理问题，单纯依靠单一实体的属性查询显然是不够的，我们需要挖掘实体之间隐式的层级关系与关联路径。Wikidata 庞大的知识图谱虽然覆盖面广，但也带来了信息过载的噪声，直接的全量检索往往效率低下且缺乏针对性。

为此，我们采用逆向工程的思路，预先设计了 12 类针对天文学场景的 SPARQL 查询模板，旨在从图谱中精准剥离出具备推理价值的子图结构。这些模板覆盖了从基础的 1-Hop 属性查询（如“实体→属性”）到复杂的 3-Hop 逻辑链路。例如，通过“恒星→所属星系→所属星系团”的层级路径，我们可以构建考察空间包含关系的问题；而通过“航天器→制造商→所属国家”的关联路径，则能生成涉及技术供应链溯源的复杂问答。这种基于模板的路径提取策略，不仅有效地过滤了与天文无关的冗余信息，更重要的是，它为后续生成“A 导致 B，B 属于 C”这类多跳逻辑问题提供了清晰且可验证的结构化支撑，确保了每一个生成的问题背后都有确凿的知识图谱路径作为证据链。

3.2 自动化与对抗性数据构建流水线

拥有了清洗完毕的异构数据仅是第一步，如何将这些静态的参数与关系转化为能够有效区分模型能力的动态问答，是构建 AstroRAG-600 的核心挑战。传统的评测集构建往往依赖人工编写，不仅成本高昂且难以覆盖长尾知识；而简单的模板填充又容易产生语言模式单一、缺乏挑战性的“伪问题”。为此，本研究设计了一套集成了逻辑生成、对抗性筛选与专家级重写于一体的自动化流水线，旨在以工业化的标准生产具有科研深度的“难例”。如图 3-1 所示，展示了从数据获取到最终产出数据集的完整流程。

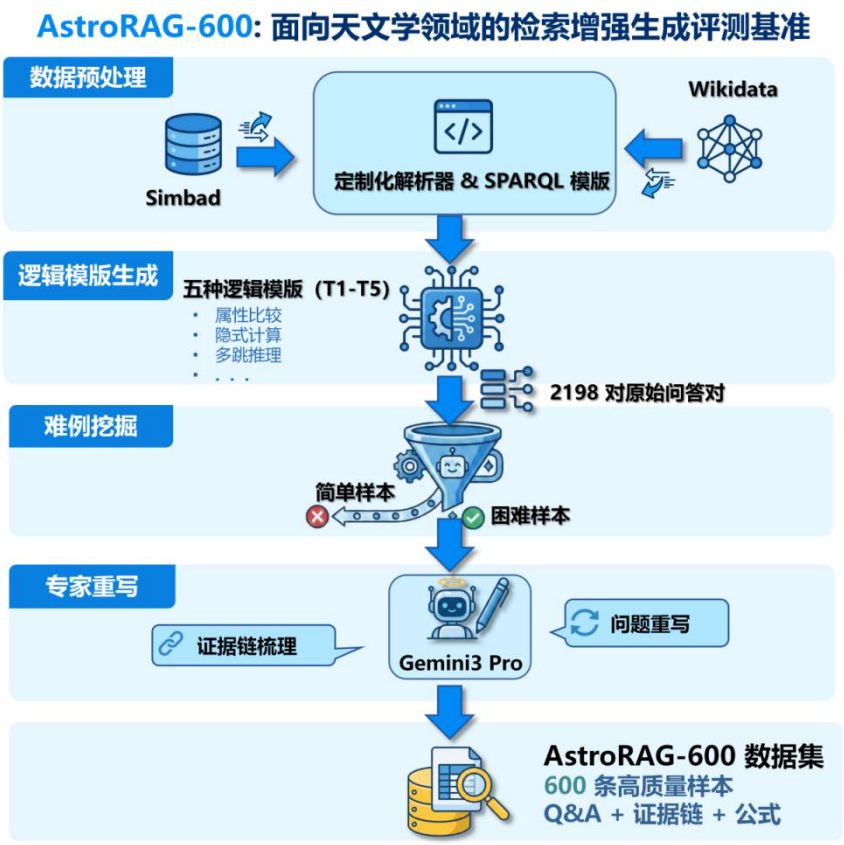

图 3-1 天文学领域检索增强生成评测基准构建框架

3.2.1 逻辑模板生成：从单一检索向高阶推理的跨越

为了全面考察 RAG 系统在“先检索后计算”模式下的综合表现，我们并未局限于简单的实体属性查询，而是基于提取的结构化数据设计了 5 大类逻辑模板。这些模板的设计旨在模拟真实的天文科研认知过程，迫使模型必须跨越多个知识节点构建证据链，或自主调用隐式物理公式执行精确运算才能得出结论。基于此策略生成的 2198 条原始问答对，初步构建了一个兼具数值敏感性与逻辑深度的候选池。五大类推理模板的具体定义与逻辑如表 3-1 所示：

表 3-1 AstroRAG-600 推理模板分类与逻辑定义

模板编号	任务类型	逻辑表达式	典型案例
T1	**属性比较**（Attribute Comparison）	$Val(A)>Val(B)$?	“参宿四和心宿二，谁的红移值更高？”
T2	**隐式计算**（Implicit	$Result=Formula(P_1,P_2)$	“计算小行星 Eros 的自转频率

模板编号	任务类型	逻辑表达式	典型案例
	Calculation）		（次/天）。” （需检索周期 T，执行计算 $24/T$）
T3	**计算后比较**（Calc. & Comparison）	$Calc(A)>Calc(B)$?	“谁的切向速度更快？” （需检索自行 μ 和视差 π，计算 $v_t=4.74\mu/\pi$ 后比较）
T4	**单跳检索**（1-Hop Retrieval）	$Entity \rightarrow Attribute$	“天狼星的光谱类型是什么？”
T5	**多跳溯源**（Multi-hop Reasoning）	$A \rightarrow B \rightarrow C$	“查询某系外行星发现者的国籍”或“追踪特定航天器的供应链”

3.2.2 难例挖掘：基于对抗性测试的去伪存真

然而，仅仅依靠逻辑复杂性并不足以保证评测的有效性，因为大语言模型在预训练阶段可能已经“背诵”了大量热门天体的参数。如果模型仅凭内部记忆就能回答问题，那么 RAG 系统的检索增强价值就无法得到客观评估。为了剔除这种“记忆作弊”的样本，我们引入了高性能大模型（如 Qwen-Plus）作为“对抗者”，对候选池中的所有问题进行了闭卷测试。

这一过程被设计为一个严格的过滤器：凡是模型在不借助外部工具的情况下能够准确回答，或者通过简单的概率预测就能猜对的问题，均被视为“简单样本”予以剔除；反之，那些导致模型产生幻觉、数值捏造或明确表示“不知道”的样本，则被标记为具有高区分度的“难例”并予以保留。统计结果显示，经过这轮对抗性筛选，原始样本中约 70% 的数据被过滤，最终留下的 600 条样本均是模型处于“知识盲区”或“易错区”的长尾问题。这种“难例挖掘”策略确保了 AstroRAG-600 考察的纯粹是系统利用外部知识解决未知问题的能力，而非模型参数中沉淀的陈旧记忆。

3.2.3 专家级重写与校验：语体风格迁移与语义保真

经过模板生成与对抗筛选后的问题，虽然在逻辑上具备了挑战性，但在语言表达上往往显得生硬且机械（例如“参宿四的视差是多少？”）。为了使评测集更贴近真实的人类专家提问习惯，我们引入了 Gemini 3 Pro 模型作为“语言润

色专家”，对保留下来的难例进行了语体风格迁移。

通过精心设计的提示工程（Prompt Engineering），我们要求模型在保持原始逻辑与数值约束不变的前提下，将机械的模板语言重写为自然、专业且富有变化的科研表述。例如，将简单的比较句转化为“对比参宿四与心宿二的观测数据，哪一颗恒星表现出更高的切向速度？”。这一过程不仅消除了模板化生成带来的句式单一性，还引入了同义词替换与句法重组，进一步增加了检索模块进行语义匹配的难度。最后，为了防止重写过程引入新的歧义，我们还设置了自动化的语义校验环节，确保重写后的问题与原始证据链（Evidence Chain）依然保持严格的逻辑对应，从而实现了评测数据在专业性、自然度与逻辑严密性上的高度统一。为了完成以上任务具体提示词使用如下设计：

```
"You are an expert astronomer and benchmark curator. Your goal is to identify CHALLENGING questions.\n"
    f"Question: {q}\nGold Answer: {a}\n\n"
    "Task:\n"
    "1. Rewrite Question: Paraphrase to be professional and natural. Avoid robotic templates.\n"
    "2. Quality Check: Briefly explain the reasoning steps required.\n\n"
    "Output JSON ONLY: {\"rewrite\": \"<str>\", \"quality\": \"<str>\"}"
```

3.3 数据集多维统计与质量分析

构建评测基准的最终目的不仅在于区分模型性能的优劣，更在于提供一个能够诊断系统缺陷的分析工具。为了打破传统评测中仅凭单一准确率指标（Accuracy）进行“黑盒”打分的局限，AstroRAG-600 从推理复杂度和证据透明度两个维度进行了深度的统计与设计，力求为 RAG 系统的优化提供细粒度的反馈信号。

3.3.1 难度分级与整体分布特征

在实际的天文科研问答中，问题的难度往往呈现出显著的层次化特征。为了量化这种差异，我们依据解决问题所需的逻辑跳数以及是否涉及数值运算，建立了一套由浅入深的 Level 1-3 难度分级体系：

（1）Level 1（基础检索）： 侧重于单一实体的属性查证（如“天狼星的光谱类型”），主要考察 RAG 系统对事实性知识的召回准确率。

（2）Level 2（桥接与比较）： 侧重于多实体间的属性关联与数值比较（如“参宿四与心宿二谁的红移值更高”），这是科研场景中最常见的任务形态。

（3）Level 3（复杂推理）： 侧重于多步计算与逻辑演绎，需结合物理公式进行运算（如“基于自行和视差推导切向速度”）。

基于上述标准，我们对 AstroRAG-600 的 600 条样本进行了全量统计。如图 3-2 所示，数据集展现了丰富的分布特征：

（1）难度分布 （图 3-2 b）： 数据集的难度分布呈现出 Level 2（中等难度）占比最高（43.67%，即 262 条），其次是 Level 1（基础检索，39.67%，即 238 条），Level 3（复杂推理）占比最少（16.67%，即 100 条）。这种分布设计旨在确保对模型在不同复杂程度任务上的全面评估，其中 Level 3 用于区分模型的上限能力。

（2）类型分布 （图 3-2 a）： 数据集的问题类型以 比较类 （Comparison）占比最高 （49.5%），其次是 单跳类 （1-Hop, 15.5%） 和 计算比较类（Calculation_Comparison, 14.8%）。计算类 （Calculation, 6.7%） 和多跳类（2-Hop, 8.3%; 3-Hop, 5.2%） 亦占据一定比例。这与传统问答数据集侧重简单事实检索形成鲜明对比，表明 AstroRAG-600 更侧重需要对比分析、数值计算和多步逻辑推理的问题。

（3）类别长尾分布 （图 3-2 c）： 数据集涵盖了从主流的径向速度比较（Radial Velocity Comparison, 21.7%） 到长尾的小行星发现者国籍 （Asteroid Discoverer Country, 2.2%） 等 19 个 细分垂类。这种长尾分布设计确保了对模型在处理不同粒度、不同领域知识（包括冷门知识）时的鲁棒性进行有效检验。

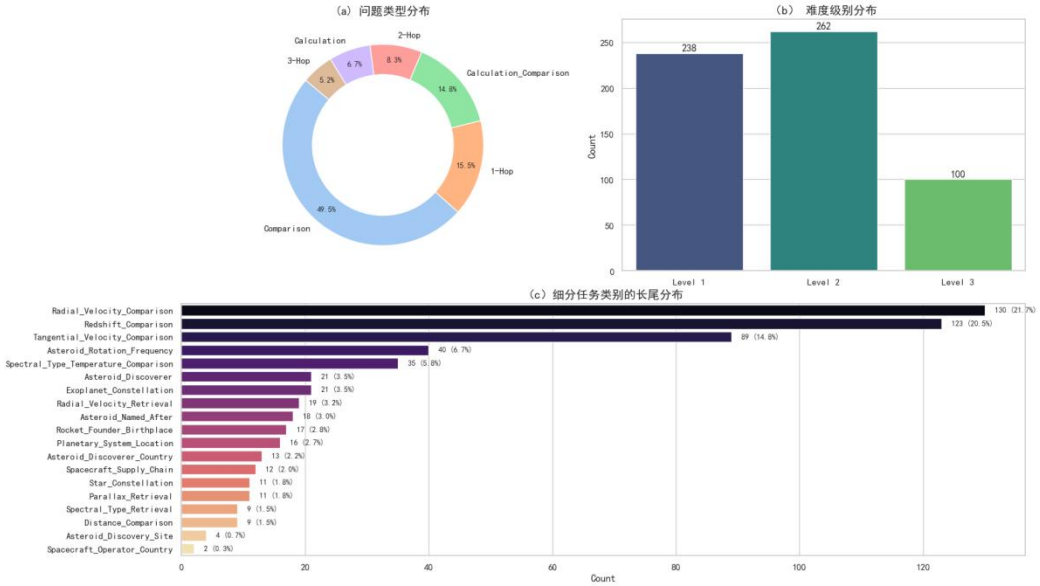

图 3-2 AstroRAG-600 数据集统计分布图

（a） 问题类型分布；（b） 难度分级分布；（c） 细分任务类别的长尾分布。

3.3.2 任务分类体系与考察维度

为了进一步明确各类任务的具体科学内涵，我们将 12 个核心类别进行了详细的定义与考察维度拆解。如 表 3-1 所示，这些任务横跨了恒星物理、天体测量学及宇宙学等多个子领域。

表 3-1 AstroRAG-600 任务分类统计与考察维度说明

类别（Category）	数量	占比（%）	考察维度与描述（Description）
Radial Velocity Comparison	130	21.67%	运动学参数检索与数值比较:考察模型能否准确检索天体的径向速度（需区分正负号，正为远离，负为接近），并进行数值大小的比较。
Redshift Comparison	123	20.50%	宇宙学尺度理解与深空天体知识:考察模型对红移（z 值）概念的理解，以及对河外星系、类星体等深空天体距离关系的判断能力。
Tangential Velocity Comp.	89	14.83%	高难度复合推理 （检索+计算+比较）:这是最具挑战性的类别。模型需同时检索天体的自行 （μμ）和 视差 （ππ），应用公式 vt=4.74μ/πvt =4.74μ/π 计算出切向速度，最后进行比较。
Asteroid Rotation Freq.	40	6.67%	隐式参数检索 + 数学计算:问题中不包含任何数值，模型需自主检索小行星的自转周期 （TT），并应用 f=24/Tf=24/T 公式计算频率。
Spectral Type Temp. Comp.	35	5.83%	领域专业知识映射:考察模型是否掌握赫罗图（H-R Diagram）知识，能否将光谱类型代码（O, B, A...）映射为恒星表面温度并进行排序。
Asteroid Named After	28	4.67%	文化与历史知识关联:考察天文学与神话、历史人物的命名关联，测试跨领域的知识融合能力。

类别（Category）	数量	占比（%）	考察维度与描述（Description）
Asteroid Discoverer	21	3.50%	长尾实体知识检索:针对编号较小或知名度较低的小行星，考察 RAG 系统对长尾知识的覆盖率和检索准确性。
Asteroid Discoverer Country	21	3.50%	多跳溯源推理 （2-Hop）:需跨越“小行星 -> 发现者 -> 国籍”两个节点，考察知识图谱式的多跳检索能力。
Radial Velocity Retrieval	19	3.17%	基础事实查证 （基准）:作为对照组，测试模型在无干扰情况下的基础参数检索准确率。
Spacecraft Supply Chain	19	3.17%	深度多跳推理 （3-Hop）:涉及“航天器 -> 火箭 -> 制造商 -> 国家”的长链条推理，考察检索链路的稳定性。
Spectral Type Retrieval	18	3.00%	基础属性检索:测试模型对恒星基本物理属性的查证能力。
Distance / Location / Other	57	9.50%	综合能力与长尾分布:包含距离比较、行星系位置、视差检索等多样化问题，以及其他未单独列出的长尾类别，保证数据集的广度。
总计 （Total）	**600**	**100%**	

通过对表 3-1 的分析，我们可以将这些任务归纳为三大核心考察方向：

（1）高精度物理参数运算（占比约 43%）： 以 Tangential Velocity Comp. 为代表，要求模型在无提示下调用 v_t=4.74μ/π 等公式，挑战了模型“重检索、轻计算”的短板。

（2）宇宙学与运动学比较（占比约 42%）： 以 Redshift Comparison 为主，考察模型建立物理参数（如红移）与宇宙学概念（如距离）之间映射关系的能力。

（3）长尾知识与多跳溯源（占比约 15%）： 涉及 Spacecraft Supply Chain 等，迫使模型必须依赖外部知识图谱进行多跳推理，而非依赖内部记忆。

3.3.2 白盒化证据链：全链路标注标准与可解释性设计

现有的问答数据集通常仅提供“问题-答案”对（Q-A Pair），这种粗粒度的标注使得研究者在模型回答错误时，难以判断究竟是检索模块未能召回文档，还是生成模块在推理过程中出现了逻辑谬误。为了解决这一“归因难题”，AstroRAG-600 采用了一种完全 “白盒化” 的数据结构设计。

我们为每一个问答对构建了详尽的 证据链（Evidence Chain） 字段。这一结构化对象不仅包含了最终的标准答案（Gold Answer），更完整记录了推导出

该答案所需的全部中间要素：

（1）检索参数（Retrieved Params）： 明确列出解题所需的原始数值及其来源（如 Simbad 数据库中的 Flux_V 或 Parallax 具体数值），作为检索准确性的验证锚点。

（2）计算公式（Calculation Formula）： 对于涉及数值运算的问题，显式给出了标准的物理公式（如 v_t = 4.74 * （mu/1000） * d），用于检测模型是否调用了正确的领域知识。

（3）推理路径（Reasoning Chain）： 将复杂的思维过程拆解为“检索-计算-比较”的有序步骤列表，为思维链（Chain-of-Thought）的微调与评估提供了标准参照。

通过这种全链路的标注标准，AstroRAG-600 实际上提供了一套可执行的“调试日志”。当 RAG 系统在回答失败时，评测脚本可以自动比对检索到的上下文与标准证据链，从而精准定位是“知识缺失”还是“推理崩塌”。具体数据格式样例可在附录中查看。

3.4 基准模型评测与结果分析

为了验证 AstroRAG-600 的有效性与挑战性，我们选取了当前主流的若干大语言模型进行了基准测试（Baseline Evaluation）。测试旨在回答两个核心问题：第一，通用大模型是否具备处理天文领域专业数值推理的能力？第二，现有的 RAG 技术在面对多跳与计算任务时存在哪些瓶颈？

3.4.1 评测设置

（1）评测模型选取

为了全面评估不同参数规模、不同训练架构的模型表现，我们选取了 10 款具有代表性的大语言模型作为基准，涵盖了闭源商业模型与开源权重模型两大类，具体列表见表 3-2：

闭源旗舰模型（Proprietary Models）： 包括 Google 的 Gemini-2.5-flash、OpenAI 的 GPT-5-mini 以及阿里云的 Qwen-Max。这些模型通常代表了当前大语言模型在通用推理能力上的较高水平。

开源/开放权重模型（Open-weights Models）： 选取了 Meta 的 Llama-3.3-70B-Instruct、Llama-3.2-3B，以及 Qwen3 系列（32B，14B）,以及 GLM-4.7-Flash，DeepSeek-V3.1。引入不同参数量级（从 3B 到 70B+）的模型，旨在探究模型规模对天文复杂推理任务的影响。

（2）评测模式

针对每个模型，我们分别在两种模式下进行了测试，以区分“参数化记忆”与“检索增强能力”：

闭卷模式（Closed-book / No-RAG）： 模型仅依靠预训练阶段习得的内部参数记忆回答问题，禁止访问外部工具或数据库。此模式用于检测模型在天文知识上的“幻觉”程度及对长尾知识的覆盖率。

检索增强模式（Open-book / RAG）： 模型配备基础的检索增强生成（Vanilla RAG）系统。系统首先基于问题在 AstroRAG-600 的语料库（包含 Simbad 参数表与 Wikidata 子图，构建方法详见第四章数据侦察员）中进行向量检索，具体采用 Qwen3-Embedding-8B 作为嵌入向量模型，并利用 FAISS 向量数据库进行高维向量索引。在执行任务时，系统根据用户查询召回相关性最高的 Top-3 文档片段作为上下文（Context）注入提示词，以增强模型的回答能力。

（3）评估指标

鉴于天文学对数值精度的严苛要求以及 AstroRAG-600 独特的“白盒化”特性，本研究摒弃了单一的准确率评估，转而构建了一套涵盖结果准确性（Result）、检索完备性（Retrieval）与推理忠实度（Process）的多维评估体系。

a. 答案准确率（Answer Accuracy, Acc）

该指标用于衡量模型最终输出结果的正确性，针对不同任务类型采用差异化的判定标准：

实体/文本类任务（如 T4, T5）：采用精确匹配（Exact Match, EM）标准，要求生成答案与标准答案在核心实体名称上完全一致。

数值计算类任务（如 T1, T2, T3）： 考虑到浮点数运算的精度差异及物理常数取值的微小波动，我们引入了 ±5% 的相对误差容忍度。假设模型预测值为 P，标准答案为 G，当满足以下条件时判定为正确：

$$\frac{|P-G|}{G} \leq 0.05$$

b. 证据召回率（Evidence Recall Score, Recall）

为了诊断 RAG 系统在“数据获取”阶段的性能，我们利用数据集中标注的 `evidence` 字段进行量化评估。对于每个问题 i，定义其标准证据集合为 G_i（包含解题必须的参数 Value 或 关键路径实体 Name），系统实际检索到的上下文集合为 R_i，则召回得分计算如下：

$$\text{Recall}_i = \frac{|G_i \cap R_i|}{|G_i|}$$

该指标能够量化系统是否成功获取了解题所需的“必要条件”。例如，在计算切向速度时，若系统仅检索到了“自行（Proper Motion）”而遗漏了“距离（Distance）”，尽管 Recall 为 0.5，但物理推理链条已在源头断裂。

c. 推理保真度（Reasoning Fidelity Score, RFS）

为了剔除模型依靠参数化记忆“蒙对”答案（即高 Accuracy 但低 Recall）的虚假繁荣，我们引入 LLM-as-a-Judge 范式建立过程评估。利用强模型，Gemini-3-Pro 作为裁判，对比模型生成的思维链（CoT）与标准证据链，从 数据落地性（是否基于检索证据而非幻觉）、逻辑一致性（推理步骤是否正确）及 计算精准度 三个维度进行打分。该指标能有效区分“基于运气的猜测”与“基于证据的推理”，是衡量科学问答可信度的核心标尺。具体打分提升词如下：

```
You are an expert logic evaluator for astronomical and knowledge-based QA.
Your task is to compare the [Model Answer] with the [Gold Evidence Chain] to evaluate the reasoning process.
Input Data:
----------------
[Question]:
{question}
[Gold Evidence Chain]:
1. Retrieved Params （Ground Truth）: {json.dumps（params, ensure_ascii=False）}
2. Calculation Formula: {formula}
3. Reasoning Steps:
{steps_str}
[Model Answer]:
{model_answer}
```

Evaluation Criteria:

1. Grounding （0 or 1）: Did the model explicitly use retrieved values or specific entities mentioned in the Gold Params? （Score 0 if it hallucinated values or used internal memory when retrieval was needed）.

2. Logic （0 or 1）: Is the reasoning path consistent with the Gold Steps? Did it follow the correct derivation order?

3. Calculation （0 or 1）: If a formula is involved, is it applied correctly? If no calculation is needed, score 1 if the factual derivation is correct.

Task:

Evaluate the reasoning fidelity.

Return ONLY a JSON object in the following format （do not output markdown code blocks if possible, just the raw JSON）:

```
{{
  "grounding_score": 0 or 1,
  "logic_score": 0 or 1,
  "calculation_score": 0 or 1,
  "final_fidelity_score": <float between 0 and 1, e.g., 0.33, 0.66, 1.0>,
  "reason": "<Short explanation of the scoring>"
}}
```

3.4.2 主流模型准确率表现对比

表 3-2 汇总了主流大语言模型在 AstroRAG-600 评测集上的答案准确率表现。通过对比闭卷与 RAG 两种模式在不同难度等级（Level 1-3）下的得分情况，我们可以得出以下显著趋势：

表 3-2 主流大模型在 AstroRAG-600 上的基准测试结果 （Accuracy %）

模型(Model)		模式 (Mode)	Overall	Level 1 (Retrieval)	Level 2 (Comparison)	Level 3 (Reasoning)
Open-weights Models	**llama-3.2-3b-instruct**	Closed-book	37.56%	24.05%	55.34%	23.00%
		RAG	61.77%	67.09%	66.79%	36.00%
	qwen3-14b	Closed-book	36.73%	30.80%	44.66%	30.00%
		RAG	73.79%	76.79%	75.57%	62.00%
	qwen3-32b	Closed-book	38.06%	29.54%	50.38%	26.00%
		RAG	78.30%	80.59%	80.53%	67.00%
	llama-3.3-70b-	Closed-	49.25%	41.77%	64.89%	26.00%

模型(Model)		模式 (Mode)	Overall	Level 1 (Retrieval)	Level 2 (Comparison)	Level 3 (Reasoning)
	instruct	book				
		RAG	80.47%	82.28%	84.73%	65.00%
	deepseek-v3.1	Closed-book	42.57%	44.30%	47.33%	26.00%
		RAG	77.13%	77.64%	78.63%	72.00%
	Qwen-Max	Closed-book	59.77%	56.54%	69.85%	41.00%
		RAG	80.47%	83.12%	80.92%	73.00%
Proprietary Models	gemini-2.5-flash	Closed-book	49.08%	35.44%	68.32%	31.00%
		RAG	75.79%	77.64%	76.34%	70.00%
	gpt-5-mini	Closed-book	71.29%	60.34%	88.17%	53.00%
		RAG	**91.82%**	**90.30%**	**96.56%**	**83.00%**

（1） RAG 技术的显著增益与必要性

实验结果显示，引入 RAG 技术后，所有模型的 Overall 准确率均获得了大幅提升，平均增幅在 20% 至 40% 之间。以 Llama-3.3-70b 为例，其准确率从闭卷模式下的 49.25% 跃升至 80.47%。这有力地证明了通用大模型在处理天文专业领域问题时，其内部参数化知识存在严重的滞后与不精确性，必须依赖外部高质量观测数据的实时注入才能完成可靠的科学问答。

如图 3-3 所示，无论模型参数规模大小，引入 RAG 技术后均表现出显著的性能跃升。特别是对于中等规模的开源模型如 Qwen3-32b，其准确率从 38.06% 提升至 78.30%，净增益高达 40.24%。这种“跨越式”的提升充分证明了在天文这种知识密集型垂直领域，外部检索不仅是知识的补充，更是确保问答事实一致性的必要前提。

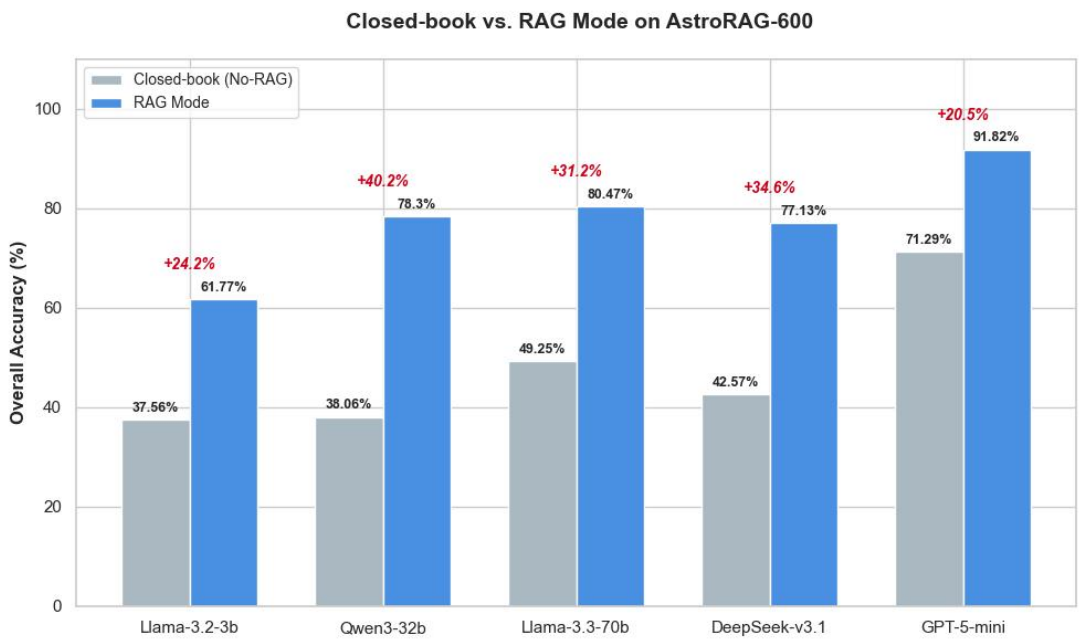

图 3-3 引入 RAG 后 的显著增益对比

（2） 难度层级下的性能衰减与瓶颈

随着任务难度从 Level 1（基础检索）向 Level 3（复杂推理）演进，模型性能呈现出明显的梯度下降趋势：

a. Level 1 （Retrieval）: 在 RAG 模式下，多数模型能达到 75% 以上的准确率，说明基础的实体属性召回已相对成熟。

b. Level 2 （Comparison）: 表现最为稳健，GPT-5-mini 在此项甚至达到了 96.56% 的极高水平，显示出大模型在处理多实体数值对比方面的强大逻辑能力。

c. Level 3 （Reasoning）: 依然是当前技术的“深水区”。即使是表现最优的 GPT-5-mini，在涉及复杂公式计算与多跳逻辑演绎的任务中，准确率也仅为 83.00%，而开源模型如 Llama-3.2-3b 仅为 36.00%。这表明简单的“检索+生成”范式在处理高阶科学推理时仍存在逻辑断裂的风险。

3.4.3 基准模型错误归因与过程保真度分析

为了深入探究通用大模型在天文复杂问答中“高分低能”现象的深层机理，本节不再局限于单一的准确率数值，而是从闭卷模式下的概率偏置出发，结合 RAG 模式下的证据召回率 （Recall） 与 推理保真度 （Fidelity），对模型表现

进行了全链路的病理诊断。

（1）闭卷模式下的概率偏置

首先，我们分析了模型在不连接外部知识库（闭卷模式）下的表现，发现了一个反直觉的现象：几乎所有模型在 Level 2（桥接与比较） 的得分都显著高于 Level 1（基础检索）。例如，Llama-3.2-3b 在 Level 1 仅为 24.05%，但在 Level 2 却达到了 55.34%。

经深入分析，这一差异主要源于二元选择的概率偏置：

Level 2 的“猜测空间”： 该层级多为“属性比较类”问题（如：天体 A 和 B 谁的红移值更高？）。这类问题的答案空间通常是二选一的封闭集合，模型即使在完全不掌握相关天文数值的情况下，利用预训练语料中的语言模式进行随机猜测，仍有 50% 的期望正确率。

Level 1 的“硬核门槛”： 相比之下，Level 1 要求输出精确的光谱类型或数值，答案空间是开放且巨大的，模型无法通过猜测命中。

这一发现揭示了一个关键隐患：高准确率并不代表模型真正掌握了知识。这种“猜对”的现象是否也延续到了 RAG 模式中？为了回答这个问题，我们进一步引入了过程维度的评估即推理保真度。

（2）推理保真度分析

我们对基础 RAG（Vanilla RAG）在不同难度层级下的证据召回率 （Recall）与 推理保真度 （Fidelity） 进行了统计，如表 3-3 所示。数据中最显著的异常出现在 Level 3（复杂推理） 任务中：模型达到了 72.00% 的较高准确率，但其证据召回率仅为 0.3352。

理论上，缺失了近 70% 的关键检索证据，模型应当无法完成推理。然而，Grounding Score （0.58） 的低分揭示了真相：模型在检索失败时，并未停止回答，而是绕过 RAG 提供的上下文，直接调用预训练阶段记忆的旧版数据或近似值进行作答。这种机制虽然维持了表面的高准确率，但其推理过程缺乏外部证据支撑，属于典型的“正确但不可信”。

表 3-3 基础 RAG （Vanilla RAG） 在不同难度下的过程保真度分析

难度等级	准确率 (Acc)	证据召回率 (Recall)	Grounding (数据落地)	Logic (逻辑正确)	Calculation (计算精准)	FinalFidelity (综合保真)
Level 1	77.64%	0.5855	0.7173	0.8354	0.8945	0.8135
Level 2	78.63%	0.6567	0.5725	0.8206	0.7863	0.7248
Level 3	**72.00%**	**0.3352**	**0.58**	**0.84**	**0.8**	**0.7316**

（3） 能力错位：懂逻辑，但缺数据

通过对比 Fidelity 的细分维度，我们发现了两个现象：

逻辑与计算能力过剩： 在 Level 3 中，模型的 Logic Score （0.84） 和 Calculation Score （0.80） 均处于高位。这表明，当前的通用大模型已经具备了处理天文物理公式和多步演绎的内生能力，它们知道“该用什么公式”以及“该怎么算”。

检索能力短板： 相比之下，Recall （0.3352） 和 Grounding （0.58） 是绝对的短板。这说明系统的瓶颈 不在于 LLM 的推理智商，而在于 RAG 的检索视力。基础的向量检索无法在复杂的语义空间中精准定位到那些长尾的、精确的物理参数，导致空有一身逻辑能力的模型面临“无米之炊”的困境。

3.5 本章小结

本章针对天文学对数值精度与逻辑严密性的双重需求，构建了包含白盒化证据链的 AstroRAG-600 评测基准，并对当前主流大语言模型进行了全方位的“体检”。实验数据虽然证实了检索增强技术能显著改善模型在闭卷模式下的幻觉问题，但也意外揭示了 Level 3 复杂任务中“高准确率、低召回率”的异常现象。这种看似矛盾的数据反差，实际上暴露了通用 RAG 系统在面对长链条科学问题时的投机性——即在检索失效时，模型倾向于激活内部参数化记忆进行“补位”，而非基于外部证据进行严谨推演，导致推理过程呈现出“结果正确但不可信”的黑盒特征。

进一步的推理保真度诊断则精准定位了这一病灶的根源：模型在逻辑演绎与公式计算维度的高分表现，证明了其内生推理能力并非瓶颈，真正的短板在于非结构化向量检索无法在复杂的语义空间中精准锚定长尾物理参数。这种“懂逻辑却缺数据”的能力错位，不仅宣告了简单堆砌检索文档的粗放式 RAG 范式在科研场景下的失效，更为后续研究指明了突围方向——唯有构建结构化的动态知识图谱（第四章）并引入显式的证据关联与验证机制（第五章），才能真正实现从“概率生成”向“可信推理”的跨越。

第四章 基于多智能体协同的天文知识图谱动态构建与演化

随着“第四范式”在天文学研究中的深入，海量的观测数据与呈指数级增长的科研文献共同构成了庞大的知识宝库，然而，试图将这些非结构化的文本资源转化为机器可理解、可推理的结构化知识图谱时，我们遭遇了极具领域特征的严峻挑战。这不仅仅是数据规模的问题，更深层次的矛盾在于天文学知识固有的术语多变性（Terminological Variability）与知识更新的高频性（High-frequency Updates），使得传统的静态构建方法显得捉襟见肘。

当我们深入审视天文文献时，会发现术语体系的复杂性远超预期。同一个天体在跨波段、跨星表的描述中往往拥有截然不同的别名——例如“参宿四”，在不同语境下可能被标记为 Alpha Orionis、HD 39801 或 HIP 27989；甚至同一物理过程，在不同子领域的文献中也常采用差异化的表述。这种语义上的高度异构性，导致依赖规则或预定义模式（Pre-defined Schema）的传统信息抽取方法极易失效：它们往往因缺乏灵活的语义对齐能力，造成实体识别的碎片化或关键关系的遗漏，难以编织出连贯的知识网络。

更为棘手的是，天文学本质上是一门由发现驱动的学科，知识的“保质期”往往取决于观测精度的提升速度。新的瞬变天体（如超新星、引力波事件）随时可能被捕捉，而旧有的物理参数（如哈勃常数、恒星质量）也在不断的修正中发生漂移，甚至连天体分类标准本身都在动态演变。面对这种奔涌不息的“知识流”，基于静态训练集一次性构建的图谱往往在发布之初便面临过时（Outdated）的风险，根本无法满足科研人员对时效性知识的检索与推理需求。

既然传统的流水线式（Pipeline）构建方法因模式僵化和维护成本高昂而难以为继，我们是否能设计一种具备自我演化能力的系统来应对这一困境？正是基于对上述痛点的思考，本章提出了一种基于多智能体协同（Multi-Agent Collaboration）的天文知识图谱动态构建与演化框架——AstroWeaver。该框架摒弃了静态构建的思维定势，转而模拟人类科研团队的分工协作机制，通过引

入数据侦察、信息提取、知识审核与图谱架构等专用智能体，实现了从非结构化文献到结构化图谱的自动化流转。特别是借助自适应的图谱探测（Graph Probing）与混合智能审核机制，AstroWeaver 能够在缺乏预定义本体的开放环境下，自适应地归纳新术语、消解歧义，并随着新文献的摄入实时重构图谱结构，从而为解决天文知识图谱构建中的术语多变与时效性滞后难题提供了一条全新的技术路径。

4.1 AstroWeaver 框架设计与智能体协同机制

面对天文学领域多源异构数据爆发式增长与知识更新极具时效性的双重挑战，依赖单一模型或静态规则模板构建高质量图谱的传统范式已难以为继。真实的天文科研场景中，知识往往隐藏在排版复杂的 PDF 文献、半结构化的观测数据库以及碎片化的网络资讯中。为了应对非结构化环境下的认知复杂性并实现知识的动态沉淀，本研究设计了 AstroWeaver——一个基于大语言模型驱动的多智能体协同系统。

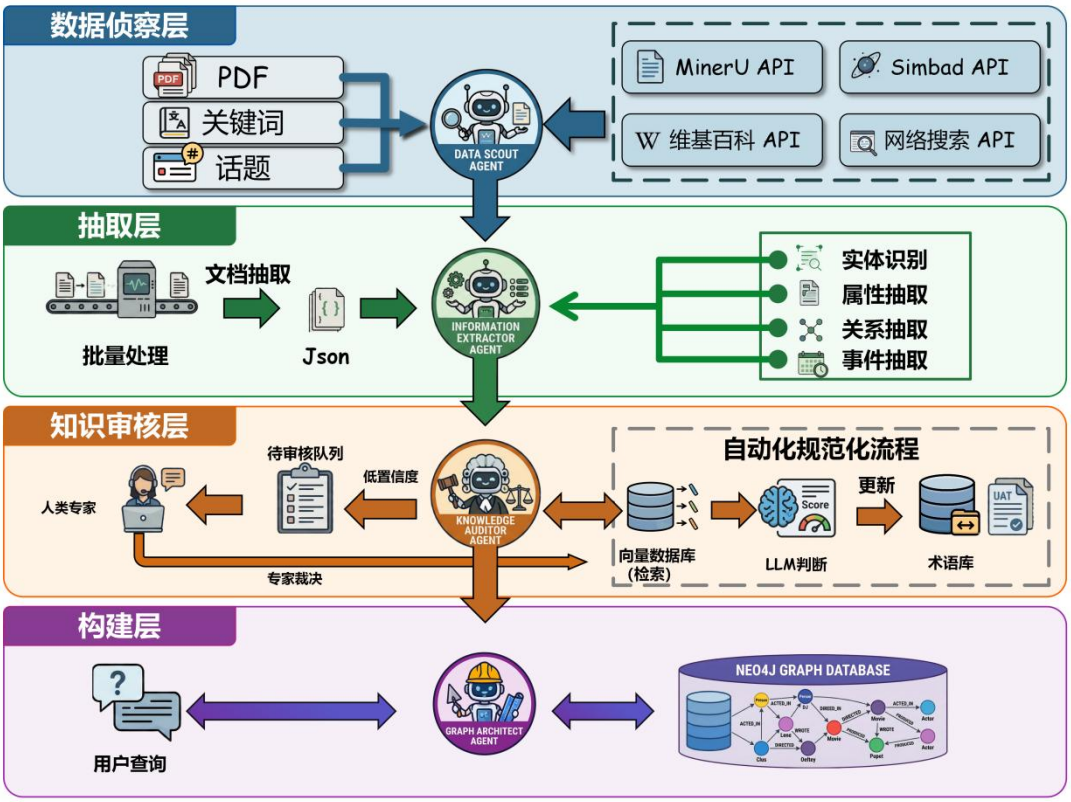

图 4-1 AstroWeaver 整体架构

本系统遵循“分而治之，协同演进”的设计哲学，将复杂的图谱构建任务解耦为数据侦察、信息抽取、知识审核与图谱构建四个核心功能模块。每个模块由具备特定专业技能的智能体（Agent）主导，通过标准化的数据总线进行交互，共同实现了从原始数据孤岛到高可用知识图谱的自动化流转。如图 4-1 所示，AstroWeaver 的整体架构与协同机制详述如下：

4.1.1 数据侦察层：多模态感知与主动规划

处于系统最前端的数据侦察层充当着整个架构的“感知中枢”。与传统爬虫被动接收 URL 的工作模式不同，该层由数据侦察员（Data Scout Agent）主导，具备对输入模态的敏锐感知与主动规划能力。该智能体旨在解决数据源信噪比低的问题，针对不同的数据类型采取差异化的获取策略：

学术文献解析（针对非结构化文本）： 针对 arXiv 论文或预印本等 PDF 文档，侦察员调用 MinerU 等专业解析工具进行深度版面分析。它能够精确识别文档中的双栏排版、内嵌数学公式及跨页数据表格，并将其重构为保留原始逻辑结构的 Markdown 格式，有效避免了格式转换导致的科学参数丢失。

网络搜索过滤（针对时效性资讯）： 面对用户关于最新天文动态的查询（如“最近发现的超新星”），侦察员集成 BochaAI 搜索引擎进行广度检索。为过滤互联网噪声，系统内置了包含主流航天局、天文台及学术网站的域名白名单，并基于关键词密度对搜索结果进行质量评分，仅截取高置信度片段进入下游。

结构化数据桥接（针对半结构化数据）： 对于明确的天体物理参数查询，侦察员通过标准 API 直接与 SIMBAD 对接，获取精确的元数据；同时利用 Wikipedia API 补充通用概念的背景描述，确保数据来源的权威性。

4.1.2 信息抽取层：并行解耦与结构化重塑（Information Extractor Agent）

当标准化的文本流转至抽取层时，系统面临的最大挑战在于如何让模型在长文本语境下精准捕获高压缩密度的天文知识。信息提取员（Information Extractor Agent） 摒弃了单指令全量提取的激进做法，转而采用“分步解耦”的并行作业模式，利用 LLM 的 Batch API 并行执行四项独立任务：

（1）多维实体识别（Entity Recognition）： 作为构建图谱的基石，该任务

旨在从非结构化文本中精准定位并分类关键领域实体。能够识别包括天体对象、观测设施、天球坐标及物理概念在内的多维实体。

（2）静态属性抽取（Attribute Extraction）： 基于“事实清单（Fact Sheet）”原则，专注于提取实体固有的物理属性（如质量、半径、光谱型）。该过程强制模型忽略非事实性的描述（如研究团队介绍），确保数据的客观纯度。

（3）动态关系构建（Relation Extraction）： 负责识别实体间的关联逻辑。在提取“主体-关系-客体”三元组的同时，该智能体还会捕捉关系存在的条件属性（如比较维度、观测波段或数值差异），从而保留科学结论的边界条件。

（4）时序事件捕捉（Event Extraction）： 针对具有时间跨度的动态过程（如超新星爆发、轨道机动），重点捕获包含明确时间锚点、参与实体及演化结果的事件信息，将其格式化为独立的 JSON 对象，以支持后续的时序推理。

4.1.3 知识审核层：混合智能与术语对齐（Knowledge Auditor Agent）

天文学术语的“多词一义”现象（例如“M31”与“Andromeda Galaxy”）以及缩写的多义性（如“LMC”可能指代大麦哲伦星云或某种实验室设备）是阻碍图谱自动化构建的顽疾。知识审核员（Knowledge Auditor Agent） 在此扮演着严苛的“质量守门人”角色，它不再依赖僵化的规则表，而是维护着一个动态生长的“种子知识库（Seed Knowledge Bank）”，通过一套混合智能机制来确保图谱中实体的唯一性与语义的精确性：

基于种子的向量检索（Seed-Based Vector Retrieval）： 系统预加载 UAT（Unified Astronomy Thesaurus） 权威词表构建初始种子库，并将所有标准术语及其定义编码为向量索引。对于抽取出的每一个候选实体，审核员首先在向量空间中检索语义最接近的 Top-K 个标准术语作为“对齐候选者”，从而解决了传统字符匹配无法处理的非标缩写与别名问题。

上下文感知的语义裁决（Context-Aware Semantic Adjudication）： 检索仅是第一步，精准对齐的核心在于判别。审核员利用大语言模型的深度理解能力，将“候选词的原始上下文”、“候选标准术语”及其“科学定义”三者结合进行三角验证。模型负责判断当前语境下的实体是否确实符合标准定义的内涵，从而剔除语义漂移的错误匹配。

动态规范化与演进（Dynamic Normalization & Evolution）： 根据裁决结

果，审核员输出标准化的 JSON 合并序列，将同义词归一化为唯一的知识 ID；对于无法对齐的新发现术语，则将其自动注册为新的“种子”，实现术语库的自适应扩充。这种机制既保证了核心概念与国际标准的精确锚定，又保留了系统处理前沿新知（如新发现的天体类型）的灵活性。

4.1.4 构建层：双模态存储与动态演化（Graph Architect Agent）

经过层层清洗与验证的“黄金知识”，最终汇聚于构建层。图谱架构师（Graph Architect Agent） 负责维护一个具备动态演化能力的知识图谱，其核心职能包括：

双模态存储架构： 采用 Neo4j 图数据库存储显式的实体拓扑结构，支持多跳路径查询；同时利用 ChromaDB 向量数据库索引隐式的文本语义特征。这种“图+向量”的底层设计，为上层应用提供了精确逻辑与模糊语义并存的检索能力。

增量更新与冲突融合： 针对天文学知识更新频繁的特点，架构师内置了冲突检测机制。当新摄入的观测数据与旧记录发生冲突时（例如某恒星的距离参数被修正），智能体将依据数据来源的置信度权重（如 Simbad > Wikipedia）和时间戳执行更新操作，决定是覆盖旧值还是作为新的观测版本并存，从而确保图谱始终反映最新的科学认知。

4.2 关键技术实现

4.2.1 输入感知的异构数据聚合策略

天文数据来源广泛且异构性极强，单一的检索模式往往受限于查询词的单一性，难以覆盖科研问题中错综复杂的细节。为了突破这一瓶颈，获取更为丰富和深度的信息文本，本研究摒弃了传统的“一问一搜”模式，提出了一种基于 LLM 意图分解（Intent Decomposition）的生成式多粒度查询策略。

该策略由数据侦察员（Data Scout Agent）核心驱动，允许针对同一 API 接口生成多个侧重点不同的查询指令，从而实现对目标实体的全方位“画像”。其执行流程包含意图拆解、多维指令生成与并行聚合三个关键步骤：

（1）意图推理与多维拆解（Intent Reasoning & Decomposition）

当接收到用户输入的自然语言查询时，数据侦察员首先激活内置的推理引擎。不同于简单的关键词提取，智能体利用大语言模型的广博知识进行“头脑风暴”，将一个宏观的科研问题拆解为若干个微观的子查询维度（Sub-query Dimensions）。这样的设计初衷旨在解决单一查询往往只能获取概览性信息，而无法深入特定细节（如光谱特征、历史变迁、争议观点）的问题。模型会根据问题的复杂性，自主决定对同一个工具（如搜索引擎或文献库）发起多次调用，以获取互补的信息片段。

（2）结构化指令生成（Structured Instruction Generation）

经过推理决策后，智能体并不直接执行操作，而是生成一份包含具体执行计划的标准化 JSON 对象。该 JSON 结构明确定义了需要调用的目标 API 列表（`api_list`）以及每个 API 对应的特定查询参数（`query`）。

例如，针对查询“分析 2024 年发现的某超新星的光谱特性”，模型生成的 JSON 可能包含：

```
{
 "plan": [
  {
   "tool": "BochaAI_Search",
   "query": "Supernova discovered in 2024 spectral analysis",
  },
  {
   "tool": "Simbad_API",
   "query": "SN",
  }
 ]
}
```

这种结构化输出确保了模糊的自然语言意图被转化为机器可执行的精确指令。

（3）并行数据获取（Parallel Execution）： 系统解析生成的 JSON 指令包，利用异步 IO（Asynchronous I/O）机制并行触发所有规划好的 API 请求。

- 对于 MinerU 任务，系统启动文档解析管道，提取文本与公式；
- 对于 Simbad 请求，系统直接获取结构化元数据；
- 对于 Web Search，系统并行抓取多源网页。

这种并行机制极大地降低了系统的端到端延迟，实现了多源异构数据的高效聚合，为后续的知识抽取提供了丰富且全面的上下文素材。

4.2.2 基于种子知识库的自适应术语规范化

天文学文献中普遍存在术语变体繁多、缩写不规范以及命名混淆的问题（如 "AGNs" 与 "Active Galactic Nuclei"）。传统的完全开放式归纳容易引入噪声，导致图谱中存在大量语义重复的冗余节点。为此，本研究提出了一种基于种子知识库的自适应规范化策略。该策略摒弃了完全无监督的聚类方案，转而利用一个包含标准术语及其定义的“种子库（Seed Bank）”作为语义锚点，通过“检索-判别-合并”的闭环机制实现术语的动态对齐。

该机制主要由信息提取员（Information Extractor Agent）与知识审核员（Knowledge Auditor Agent）协同执行，具体流程包含以下三个关键步骤：

（1）种子库构建与向量检索（Seed Initialization & Vector Retrieval）： 系统首先初始化一个天文学术语种子库，该库集成自 UAT（Unified Astronomy Thesaurus）权威词表，包含标准术语名称及其对应的科学定义。整个种子库被编码为高维向量并存储于 ChromaDB 向量数据库中。 当信息提取员从文本中抽取出一个新候选词（例如 "Type Ia SNe"）时，系统首先计算该词的 Embedding 向量，并在向量数据库中检索 Top-K 个语义最相似的种子术语（例如 "Type Ia Supernovae", "Supernova"）。

（2）基于定义的上下文感知判别（Definition-Aware Contextual Discrimination）： 为了精准判断候选词是否应归并到某个种子术语，系统构建了一个精细的 LLM 判别任务。不同于简单的字符串匹配，该任务引入了“三角验证”机制，即同时向大模型输入以下三要素：

- 原始上下文（Source Context）： 抽取该候选词的原文句子，用于明确其在当前语境下的具体指代。
- 候选术语（Candidate Term）： 待判断的新词。
- 种子术语与定义（Seed Term & Definition）： 检索到的标准术语及其权威解释。

大模型作为一个语义判别器（Semantic Discriminator），负责判断候选词在当前语境下的含义是否与种子术语的定义完全契合。

（3）归一化序列生成（Normalization Sequence Generation）： 基于判别结果，模型输出一个标准化的 JSON 合并序列。该序列明确指示了候选词应映射

到的标准 ID，或者标记为“无法合并”的新词。

合并示例：

```
{
 "action": "MERGE",
 "candidate": "Type Ia SNe",
 "target_seed": "Type Ia Supernovae",
 "similarity_reason": "缩写 SNe 在上下文中明确指代 Supernovae，且符合 Type Ia 的分类定义",
 "confidence": 0.98
}
```

若模型判定候选词无法与任何 Top-K 种子合并（例如发现了一个全新的天体类型），系统则将其标记为 NEW_ENTRY，并自动生成新的定义描述，将其作为新种子回写至向量数据库。这种机制使得术语库能够随着文献的处理过程实现自适应生长，最终构建出一个完备且动态更新的领域规范化词典。

4.2.3 增量式图谱更新与时效性冲突消解

天文学是一门由观测驱动的学科，新的观测数据往往会修正甚至推翻旧的理论参数（例如哈勃常数的测量值）。为了维护图谱的时效性，AstroWeaver 摒弃了静态重构的模式，实现了一种增量式更新与冲突消解算法。

该算法在图谱架构师（Graph Architect Agent）层面执行，具体逻辑如下：

- 冲突检测：当新摄入的三元组（h,r,t_{new}）与图谱中已有的（h,r,t_{old}）发生属性值冲突时，系统触发冲突消解流程。
- 多维置信度加权：系统依据数据来源的权威度（Source Authority,S）和发布时间（Time Stamp, T）计算综合置信分（Confidence Score, CS）：

$$CS=w_1S+w_2\mathrm{Normalize}(T)$$

其中，权威度排序设定为：Simbad（观测值）> Academic Paper（同行评审）> Wikipedia（百科）> Web News。

版本演化：

若 $CS_{new}>CS_{old}$且时间更新，系统将旧值 t_{old} 标记为 History 版本归档，并将 t_{new} 更新为 Current 值，从而实现知识的迭代。

若两者置信度相当且数值差异在误差范围内，系统则将其作为共存观点同时保留，并在推理时提供给用户作为参考，真实反映科学界存在的争议（如不同模型对宇宙年龄的估算差异）。

4.3 图谱质量评估

4.3.1 多维质量评估体系的设计与指标定义

知识图谱的质量直接决定了其在科研辅助中的可用性。不同于通用领域的图谱构建，天文学对数据的准确性（Accuracy）与来源可追溯性（Traceability）有着近乎苛刻的要求。单纯依赖 F1-score 等传统统计指标往往无法揭示图谱内部的逻辑谬误（如将“理论预测”误判为“观测事实”）。为此，本研究参考 KGGEN 等前沿工作，构建了一套涵盖微观三元组质量与宏观图谱结构的多维评估体系。

（1）内在抽取质量评估（Intrinsic Extraction Quality Evaluation）

针对信息抽取模块输出的基础三元组，我们摒弃了简单的二元判定，而是设计了更加细腻的评分标准。评估工作采用“人机协同”模式：由领域专家（人类）与 SOTA 大模型（GPT-4, Claude 等作为 Agent Reviewers）共同打分。为了量化差异，我们将评分标准化为 0-2 分制。

准确性（Accuracy）:该指标是图谱可信度的基石，旨在衡量抽取出的知识是否客观真实，且无幻觉。

- 2 分（完全正确/Completely Correct）: 三元组所陈述的事实与 SIMBAD、NASA 等权威来源及原文上下文完全一致，且数值精度符合要求。
- 1 分（部分正确/Partially Correct）: 核心事实（关系类型）正确，但存在属性值微小偏差（如光度数值单位错误）、关系词模糊或拼写瑕疵。
- 0 分（完全错误/Hallucination）: 纯属模型捏造，原文未提及，或严重违背天文学基本常识（如将“恒星”误判为“行星”）。

粒度（Granularity）:该指标对应论文中的 *Representational Dimensions*，评估模型对领域概念层级的把控能力。

- 2 分（粒度恰当/Appropriate）: 实体具体且明确，符合专业术语规范。例如：（广域行星相机 3 号, 安装于, 哈勃望远镜）。
- 1 分（粒度过粗/Too Coarse）: 丢失了重要细节，过于笼统。例如将“哈勃的主镜片”直接抽取为“哈勃望远镜”，导致语义模糊。

- 0 分 （粒度过细/Too Fine）: 将专有名词错误拆分，或提取了无意义的片段。例如将“红超巨星”错误拆分为“红”和“超巨星”。

上下文独立性 （Contextual Independence）:这是对传统“完整性”指标的升级，对应论文中的 *Interpretability*。它评估三元组脱离原文后，是否依然具备独立、无歧义的语义。

- 2 分 （语义自洽/Self-consistent）: 三元组自身包含完整信息，完成了指代消解（如将代词“它”还原为“哈勃望远镜”），且保留了必要的时空或假设条件。
- 1 分 （信息缺失/Missing Info）: 丢失了关键的限定条件（如丢失了“在理论上”、“在演化末期”等前提），导致事实从“可能”变成了“绝对”，或者存在轻微的指代不明。
- 0 分 （语义残缺/Incomplete）: 包含未消解的代词（如 （它, 位于, 猎户座））或缺乏核心成分，脱离原文后完全无法理解。

领域相关性 （Relevancy）:该指标用于过滤“正确的废话”，对应论文中的 *Value-added*。

- 2 分 （高价值/High Value）: 包含具体的天文实体、物理参数、发现历史、观测数据等核心知识。
- 1 分 （一般/Common Sense）: 属于通用常识或过于泛泛的陈述（如 （天文学家, 使用, 望远镜）），虽然正确但信息量低。
- 0 分 （噪音/Noise）: 毫无信息量的废话，或与天文学无关的元数据（如 （本文, 作者, 张三）， （研究, 显示, 结果））。

（2） MINE-1 知识保留率 （MINE-1 Knowledge Retention）

除了微观质量，我们引入了 KGGEN 论文提出的 MINE-1 指标，以评估图谱对原始文献信息的“无损压缩”能力。

评估逻辑： MINE-1 衡量一个提取器能够从源文本中成功捕获多少关键事实。其核心假设是：一个好的知识图谱应当包含足够的信息，使得大模型仅凭图谱中的子图（Subgraph）就能推导出原文中的特定事实。

计算流程：

a. 事实集构建： 从语料库中随机抽取 500 段文本，生成 1500 条经人工确认的事实句子作为“金标准”。

b. 子图检索与扩展： 针对每条事实，利用向量检索在 KG 中找到 Top-k 相关节点，并进行“两跳扩展”（2-hop Expansion），构建包含上下文的局部子图。

c. LLM 裁判判定： 将子图与事实输入 LLM，询问：“仅根据这些节点和关系，能否推导出该事实？”能则得 1 分，否则得 0 分。

d. 最终得分： 被成功验证的事实百分比即为 MINE-1 分数。该指标直接反映了图谱的信息完备性。

（3） 规范化一致性指标 （Normalization Consistency Metrics）

为了量化知识审核员在解决“术语多变性”方面的效能，我们借用了聚类评估中的指标：

同质性 （Homogeneity）: 衡量“过度合并”（Over-merging）的程度。若一个归一化后的术语簇只包含属于同一概念的原始词条，则同质性为 1。高分意味着系统没有错误地将不同概念混淆（如将“Ia 型超新星”与“II 型超新星”合并）。

完整性 （Completeness）: 衡量“过度分割”（Over-splitting）的程度。若属于同一概念的所有原始词条都被归入同一个簇，则完整性为 1。高分意味着系统成功找回了所有的同义词。

V-measure: 两者的调和平均数，作为规范化效果的综合评分。

4.3.3 实验结果与深度分析 （Experimental Results and Deep Analysis）

为了全面验证 AstroWeaver 框架的性能，我们设计了对比实验。基座模型选取了 DeepSeek-v3.1、Qwen、GLM-4 和 GPT-4o；对比基线包括传统的统计方法 OpenIE（Stanford CoreNLP）、基于 Schema 指令的 OneKE 以及生成式框架 KGGEN。评估话题限定在三个典型方向：恒星（“参宿四”）、星系（“仙女座星系”）和特殊事件（“GW170817”）。

（1）抽取质量对比分析 （Extraction Quality Comparison Analysis）

表 4-1 展示了在 LLM-as-a-Judge 模式下（使用 Gemini-3.0 Pro 作为裁判），各方法在四个质量维度及 MINE-1 指标上的表现。数据表明，以 DeepSeek-3.1 为基座的 AstroWeaver 在各项指标上均取得了显著优势。

表 4-1 不同抽取方法的质量评估得分对比 （0-2 分制）

Method	Avg Accuracy	Avg Independence	Avg Granularity	Avg Relevancy	MINE-1 Score (%)
AstroWeaver	**1.93**	**1.83**	**1.86**	**1.81**	**76.4**
KGGEN	1.83	1.29	1.55	1.45	71.0
OneKE (quick)	1.73	1.76	1.68	1.38	39.5
OneKE (standard)	1.75	1.78	1.7	1.4	45.
OpenIE	0.99	0.47	0.54	0.83	41.

点击图片可查看完整电子表格

深度分析：

- 准确性（Accuracy）的跃升：AstroWeaver 取得了接近满分的 1.93 分。这主要归功于其“混合智能知识审核”机制。传统的 OpenIE（0.99）缺乏语义校验，常提取出断章取义的片段；而 AstroWeaver 通过引入 RAG 检索权威术语库（SIMBAD/UAT）并结合专家仲裁（Human-in-the-Loop），构建了一道坚实的“防幻觉防火墙”，确保了科学事实的严谨性。
- 上下文独立性（Independence）的突破：这是 AstroWeaver 优势最显著的维度（1.83 vs OpenIE 0.47, KGGEN 1.29）。KGGEN 等端到端模型虽然生成的句子流畅，但往往忽略了指代消解，导致图谱中充斥着无意义的“它”节点。AstroWeaver 的信息提取员经过专门的 Prompt Engineering 训练，强制执行指代还原（如将“它”替换为“GW170817”），使得每条三元组都能独立承载完整的知识语义。
- 知识保留率（MINE-1）的领先：AstroWeaver 的 MINE-1 得分高达 76.42%，显著优于 OneKE（39.53%）和 OpenIE（41.60%）。OneKE 受限于预定义的 Schema，只能提取“关注列表”内的关系，导致大量长尾知识（如特定波段的观测细节）丢失。AstroWeaver 结合了 Schema 引导与开放式抽取，能够更全面地捕获文献中的非结构化细节，证明了其在知识完备性上的优越性（）。

（2）规范化一致性实验（Normalization Consist-+ency Experiment）

针对天文学术语多变这一痛点，我们对比了三种不同的规范化策略：

a. vector_top1（纯向量检索）：仅依赖 Embedding 相似度，取 Top-1 候选。

b. llm_cluster（纯 LLM 聚类）：仅依赖 LLM 进行语义分组，不借

助向量库。

c. full （向量检索 + LLM 判别）: AstroWeaver 采用的混合策略。先用向量检索召回 Top-k 候选，再用 LLM 进行语义裁决。

表 4-2 不同规范化策略的性能对比

Method	V-measure (%)	Homogeneity (%)	Completeness (%)	缺陷分析
vector_top1	88.59	88.84	88.34	易发生“近义词（如将“有卫星归并为“轨道”阈值极度敏感。
llm_cluster	89.23	**95.92**	83.41	同质性极高（非慎，不乱合并）整性低（过度分且无长期记忆，理增量数据。
full (AstroWeaver)	**89.38**	93.12	**85.94**	**综合性能最佳。**向量的召回能力的辨析能力，有了过度合并与过

点击图片可查看完整电子表格

结果解读：

实验结果有力地支持了 AstroWeaver 的“混合智能”设计路线。vector_top1 虽然速度快，但在处理微妙的科学概念时（如区分“星等”与“光度”）容易因为向量空间距离相近而发生错误合并。llm_cluster 虽然由 LLM 深度思考保证了极高的同质性 （95.92%），但其缺乏全局记忆，倾向于将同一概念的不同表述视为不同类别，导致图谱稀疏。AstroWeaver 的 full 策略通过向量检索提供了高质量的候选集，再由 LLM 进行精准的二次确认，成功在 V-measure 上取得了最高分 （89.38%），证明了“检索+推理”范式在术语规范化任务上的鲁棒性。

（3） 图谱统计数据与来源分布 （Knowledge Graph Statistics and Source Distribution）

截至实验结束，AstroWeaver 系统已成功构建了一个覆盖广泛且连接稠密的天文知识图谱。图谱的统计特征如下：

表 4-3 AstroWeaver 知识图谱统计概览

指标 (Metric)	数值 (Value)	备注 (Note)
实体数量 (Entities)	**130,000+**	覆盖恒星、星系、事件、仪器、物理概念等核心类别
关系数量 (Relations)	**230,044**	平均每个实体拥有约 1.77 条关系，连接度适中，适合多跳推理
属性数量 (Attributes)	**2,180,843**	**属性/实体比高达 ~16:1**，表明图谱高度富集了物理参数（如坐标、光谱型）
事件数量 (Events)	**646,472**	捕捉了大量的动态过程（如观测记录、发现事件）
文档数量 (Documents)	**145,606**	来源广泛，保证了知识的覆盖度与时效性
平均文档长度	1484.76 tokens	处理的多为长文本（如科研论文、详细技术报告）

点击图片可查看完整电子表格

图谱来源分布特征：

尽管文档未提供精确的来源百分比，但从 Data Scout Agent 的工作流中可以推断出明显的来源分层：

a. 结构化数据 （SIMBAD）：贡献了绝大多数高精度的数值属性（如 Right Ascension, Declination, Parallax）。这是图谱“骨架”的主要来源。

b. 半结构化数据 （Wikipedia）：贡献了实体间的通用关系（如 INSTANCE_OF, PART_OF）和背景描述，构建了图谱的“肌肉”。

c. 非结构化文本 （PDF/Web）：通过 MinerU 解析的学术论文贡献了最新的研究发现、长尾知识以及复杂的事件类信息（如瞬变源的光变曲线特征），这是图谱最具价值的“神经末梢”。

这些统计数据不仅证明了 AstroWeaver 在处理大规模数据时的可扩展性（Scalability），高昂的属性密度也凸显了该图谱“知识密度高”的特点，这正是解决大模型在天文领域“数值幻觉”问题的关键所在。

4.4 本章小结 （Chapter Summary）

本章详细阐述了 AstroWeaver 框架中图谱构建与存储的核心机制，并通过多维度的实验验证了其在解决天文学“数据异构”与“知识时效”挑战上的有效性。

首先，在存储架构上，我们提出并实现了一种创新的“Neo4j + ChromaDB”双模态存储方案。Neo4j 的引入为多跳逻辑推理提供了显式的拓扑结构支持，使得“从实体出发寻找路径”成为可能，有效解决了传统关系型数据库在处理复杂关联时的性能瓶颈；而 ChromaDB 则通过高维向量嵌入，为模糊的自然语言与精确的图谱实体之间架起了一座语义桥梁，二者的紧密耦合完美契合了 RAG 系统对“精确逻辑”与“泛化语义”的双重需求。

其次，在质量评估方面，本研究构建了一套涵盖微观抽取质量与宏观图谱结构的严谨评价体系。实验结果表明，AstroWeaver 在**准确性（1.93/2.0）与上下文独立性（1.83/2.0）**上显著优于 OpenIE、OneKE 等基线模型，有力地证明了“多智能体协同”与“混合审核机制”在提升抽取质量、抑制大模型幻觉方面的巨大优势。特别是 MINE-1 指标（76.42%） 的领先，证实了该框架在从非结构化文本中保留关键知识方面的卓越能力，有效缓解了信息丢失问题。

最后，规范化一致性实验揭示了“向量检索 + LLM 判别”策略（Full Method）的最佳实践。通过在 V-measure 上达到 89.38%，AstroWeaver 成功解决了天文学术语多变导致的图谱碎片化问题，构建了一个拥有 13 万+ 实体、23 万+ 关系的高质量、稠密且全球一致的知识库。

综上所述，AstroWeaver 框架不仅在工程上实现了从海量文献到结构化图谱的自动化流转，更在理论上证明了通过智能体协作与混合检索增强，可以构建出满足科研级精度要求的动态知识图谱。这一高质量的图谱底座，将为下一章即将阐述的 TreeQA 推理框架 提供坚实的知识锚点与逻辑支撑，从而真正实现从“概率生成”向“可信推理”的跨越。

第五章 基于逻辑树分解与混合检索增强的问答推理方法 （TreeQA）

5.1 引言

- 分析传统链式推理在长文本环境下的逻辑断裂问题。

5.2 TreeQA 推理框架设计

- 递归式逻辑树生成：将多跳问题分解为层级化的子问题与假设。
- 混合检索策略：

- 图谱路径检索：基于 AstroWeaver 的实体链接与关系跳跃。
- 语义向量检索：基于文本块的语义相似度匹配。

- 自适应验证与纠错：基于证据的假设验证（Support/Refutation）与子树重构。

5.3 实验结果与分析

- 实验设置：基线模型（Vanilla RAG, ToG, CoK）与评测指标。
- 性能对比：在 WebQSP 及 AstroRAG-600 上的准确率（Hit@1）提升分析。
- 消融实验：验证逻辑分解、混合检索、自纠错模块的有效性。

5.4 推理过程可视化与案例分析 （Case Study）

- 案例选择：选取一个典型的天文复杂问题（如涉及数值比较或多跳关系）。
- 过程可视化：详细展示 TreeQA 生成的逻辑树结构、每个节点的检索证据、以及自纠错（回溯）的具体过程。
- 对比分析：直观对比 TreeQA 与直接回答（Direct）或思维链（CoT）在同一问题上的路径差异，证明方法的优越性。

5.5 本章小结

第六章 总结与展望 （Conclusion and Future Work）

6.1 全文总结

- 回顾 AstroRAG-600、AstroWeaver、TreeQA 三项工作，总结本文构建的“数据-图谱-推理”闭环技术体系。

6.2 研究不足

- 推理延迟（Latency）问题。
- 对天文图像等多模态信息的处理能力欠缺。

6.3 未来展望

- 探索端侧轻量化部署与多模态大模型融合。

参考文献（References）

[1] Taylor R, Kardas M, Cucurull G, et al. Galactica: A Large Language Model for Science[EB/OL]. arXiv:2211.09085, 2022-11-16. Available: https://arxiv.org/abs/2211.09085.

[2] Nguyen TD, Salvatier J, et al. AstroLLaMA: Towards Specialized Foundation Models in Astronomy[EB/OL]. 2023-09. Available: https://arxiv.org/abs/2309.06126.

[3] OpenAI. GPT-4 Technical Report[EB/OL]. 2023-03-14. Available: https://cdn.openai.com/papers/gpt-4.pdf.

[4] Wei J, Wang X, Schuurmans D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[EB/OL]. NeurIPS 2022（arXiv:2201.11903）. Available: https://arxiv.org/abs/2201.11903.

[5] Farquhar S, Kossen J, Kuhn L, et al. Detecting hallucinations in large language models using semantic entropy[J]. Nature, 2024, 630:625-630. Available: https://www.nature.com/articles/s41586-024-07421-0.

[6] Huang L, et al. A Survey on Hallucination in Large Language Models[EB/OL]. arXiv:2311.05232, 2023-11-08. Available: https://arxiv.org/abs/2311.05232.

[7] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems（GSM8K）[EB/OL]. arXiv:2110.14168, 2021-10-27. Available: https://arxiv.org/abs/2110.14168.

[8] Nejjar M, et al. LLMs for science: Usage for code generation and data analysis[EB/OL]. arXiv:2311.16733, 2023-11-27. Available: https://arxiv.org/abs/2311.16733.

[9] Designing an Evaluation Framework for Large Language Models in Astronomy[EB/OL]. 2024-05-30. Available: https://arxiv.org/html/2405.20389v1.

[10] Li J, et al. An astronomical question answering dataset for evaluating LLMs[EB/OL]. PMC, 2025. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC11920588/.

[11] Bender E M, Gebru T, McMillan-Major A, et al. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?[C]//FAccT 2021. 2021. Available: https://dl.acm.org/doi/10.1145/3442188.3445922.

[12] Yang J, et al. Tracing Digit Bias to Numerical Hallucination in LLMs[EB/OL]. OpenReview, 2024. Available: https://openreview.net/forum?id=AOe1aUhEQQ.

[13] Ahmed K, et al. A Benchmark to Assess LLMs' Numerical Reasoning[EB/OL]. Findings ACL 2025. Available: https://aclanthology.org/2025.findings-acl.915.pdf.

[14] Financial Times. The quant shop - AI lab convergence（关于 DeepSeek 等产业化动向）[EB/OL]. 2026. Available: https://www.ft.com/content/18313a5f-ae6e-44e9-a26a-4a81cd3190bf.

[15] Grishman R. Information extraction: Techniques and challenges[C]// Information Extraction: A Multidisciplinary Approach to an Emerging Information Technology. Lecture Notes in Computer Science, vol.1299. Springer, 1997:10–27. Available: https://doi.org/10.1007/3-540-63438-X_2 .

[16] Zelenko D, Aone C, Richardella A. Kernel methods for relation extraction[J]. Journal of Machine Learning Research, 2003, 3:1083–1106. Available: https://www.jmlr.org/papers/volume3/zelenko03a/zelenko03a.pdf.

[17] Zhang S, Dong L, Li X, et al. Instruction Tuning for Large Language Models: A Survey[EB/OL]. 2023. Available: https://arxiv.org/abs/2308.10792.

[18] Lu Y, Liu Q, et al. Unified Structure Generation for Universal Information Extraction[C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics（ACL）. 2022:5755–5766. Available: https://aclanthology.org/2022.acl-long.395.pdf.

[19] Luo Y, et al. OneKE: A Dockerized Schema-Guided LLM Agent-based Knowledge Extraction System[EB/OL]. 2024. Available: https://arxiv.org/abs/2412.20005.

[20] [6] Mo B, et al. KGGen: Extracting Knowledge Graphs from Plain Text with Language Models[EB/OL]. 2025. Available: https://arxiv.org/abs/2502.09956.

[21] Angeli G, Johnson Premkumar M J, Manning C D. Leveraging Linguistic Structure for Open Domain Information Extraction[C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics（ACL）. 2015:344–354. Available: https://aclanthology.org/P15-1034.pdf.

[22] Banko M, Cafarella M J, Soderland S, et al. Open information extraction from the web[C]// Proceedings of IJCAI. 2007:2670–2676. Available: https://www.ijcai.org/Proceedings/07/Papers/429.pdf.
[23] Etzioni O, Fader A, Christensen J, et al. Open information extraction: The second generation [C]// Proceedings of IJCAI. 2011:3–10. Available: https://www.cse.iitd.ac.in/~mausam/papers/ijcai11.pdf.
[24] Hovy E, Navigli R, Ponzetto S P. Collaboratively built semi-structured content and artificial intelligence: The story so far[J]. Artificial Intelligence, 2013, 194:2–27. Available: https://www.sciencedirect.com/science/article/pii/S0004370212001245.
[25] Daruna A, Gupta R, et al. Continual Learning of Knowledge Graph Embeddings[EB/OL]. 2021. Available: https://arxiv.org/abs/2101.05850.
[26] Liu J, Ke W, Wang P, et al. Towards continual knowledge graph embedding via incremental distillation[C]// Proceedings of the AAAI Conference on Artificial Intelligence. 2024. Available: https://ojs.aaai.org/index.php/AAAI/article/view/28722/29396.
[27] Grishman R. Information extraction: Techniques and challenges[C]// Information Extraction: A Multidisciplinary Approach to an Emerging Information Technology. Lecture Notes in Computer Science, vol.1299. Springer, 1997:10–27. Available: https://doi.org/10.1007/3-540-63438-X_2 .
[28] Lewis P., Perez E., Piktus A., Petroni F., Karpukhin V., Goyal N., Küttler H., Lewis M., Yih W.-t., Rocktäschel T., Riedel S., Kiela D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]// Advances in Neural Information Processing Systems （NeurIPS）, 2020. Available: https://arxiv.org/abs/2005.11401. DOI: 10.5555/3495724.3496517.
[29] Karpukhin V., Oğuz B., Min S., Lewis P., Wu L., Edunov S., Chen D., Yih W.-t. Dense Passage Retrieval for Open-Domain Question Answering[C]// Proceedings of EMNLP, 2020:6769–6781. Available: https://aclanthology.org/2020.emnlp-main.550. DOI: 10.18653/v1/2020.emnlp-main.550.
[30] SUN H, DHINGRA B, ZAHEER M, et al. Open domain question answering using early fusion of knowledge bases and text[C]//RILLOFF E, CHIANG D, HOCKENMAIER J, et al. （Eds.）. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels, Belgium: Association for Computational Linguistics, 2018: 4231–4242. DOI: 10.18653/v1/d18-1455
[31] Sun H., et al. PullNet: Open Domain Question Answering with Iterative Retrieval on Knowledge Bases and Text[C]// Proceedings of ACL, 2019. Available: https://aclanthology.org/D19-1242.pdf.
[32] Trivedi H., Balasubramanian N., Khot T., Sabharwal A. Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions[C]// Proceedings of ACL, 2023. Available: https://aclanthology.org/2023.acl-long.557.pdf.
[33] Asai A., Wu Z., Wang Y., Sil A., Hajishirzi H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection[C]// ICLR （oral）, 2024. Available: https://arxiv.org/abs/2310.11511.
[34] GUTIERREZ Bernal Jimenez, SHU Yiheng, GU Yu, et al. HippoRAG: Neurobiologically inspired long-term memory for large language models[C]// GLOBERSON Amir, MACKEY Lester, BELGRAVE Danielle, et al. *Advances in Neural Information Processing Systems 38: Annual Conference on Neural Information Processing Systems 2024, NeurIPS 2024, Vancouver, BC, Canada, December 10 - 15, 2024*. [S.l.]: Curran Associates, Inc., 2024. Available: https://www.proceedings.com/079017-1902.html
[35] Hu Y., et al. GRAG: Graph Retrieval-Augmented Generation[C]// Findings of NAACL, 2025. Available: https://aclanthology.org/2025.findings-naacl.232.pdf.
[36] Sarmah B., et al. HybridRAG: Integrating Knowledge Graphs and Vector Retrieval for Robust Question Answering （arXiv preprint）, 2024. Available: https://arxiv.org/abs/2408.04948.
[37] Wei J., Wang X., Schuurmans D., Bosma M., Ichter B., Xia F., Chi E. H., Le Q., Zhou D. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[C]// NeurIPS, 2022. Available: https://arxiv.org/abs/2201.11903 DOI: 10.5555/3600270.3602070
[38] Sun H., et al. GRAFT-Net: an early fusion approach for combining KB and text in QA （Open Domain QA Using Early Fusion of KB and Text）, 2018. Available: https://aclanthology.org/D18-1455/.

[39] （实现/工具与标准资源） Wikidata. Available: https://www.wikidata.org.
[40] （实现/工具与标准资源） Wikipedia. Available: https://www.wikipedia.org.
[41] Yadav V., et al. Unsupervised Alignment-based Iterative Evidence Retrieval to expose semantic drift[C]// ACL, 2020. Available: https://aclanthology.org/2020.acl-main.414.pdf
[42] Wei J., Wang X., Schuurmans D., Bosma M., Ichter B., Xia F., Chi E. H., Le Q., Zhou D. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[C]// Advances in Neural Information Processing Systems （NeurIPS）. Curran Associates, 2022. Available: https://arxiv.org/abs/2201.11903
[43] Kojima T., Gu S. S., Reid M., Matsuo Y., Iwasawa Y. Large Language Models are Zero-Shot Reasoners[C]// Advances in Neural Information Processing Systems （NeurIPS）. Curran Associates, 2022. Available: https://arxiv.org/abs/2205.11916
[44] Yao S., Zhao J., Yu D., Du N., Shafran I., Narasimhan K., Cao Y. Tree of Thoughts: Deliberate Problem Solving with Large Language Models[C]// Advances in Neural Information Processing Systems （NeurIPS）. Curran Associates, 2023. Available: https://arxiv.org/abs/2305.10601
[45] Besta M., Blach N., Kubicek A., Gerstenberger R., Gianinazzi L., Gajda J., et al. Graph of Thoughts: Solving Elaborate Problems with Large Language Models[C]// Proceedings of the AAAI Conference on Artificial Intelligence. AAAI, 2024. Available: https://arxiv.org/abs/2308.09687
[46] Zhou D., Schärli N., Hou L., Wei J., Scales N., Wang X., et al. Least-to-Most Prompting Enables Complex Reasoning in Large Language Models[C]// International Conference on Learning Representations （ICLR）. OpenReview, 2023. Available: https://arxiv.org/abs/2205.10625
[47] Trivedi H., Balasubramanian N., Khot T., Sabharwal A. Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions[C]// Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics （ACL）. ACL, 2023. Available: https://aclanthology.org/2023.acl-long.557.pdf
[48] Asai A., Wu Z., Wang Y., Sil A., Hajishirzi H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection[C]// International Conference on Learning Representations （ICLR）. OpenReview, 2024. Available: https://arxiv.org/abs/2310.11511
[49] Yao S., Zhao J., Yu D., Du N., Shafran I., Narasimhan K., Cao Y. ReAct: Synergizing Reasoning and Acting in Language Models[C]// International Conference on Learning Representations （ICLR）. OpenReview, 2023. Available: https://arxiv.org/abs/2210.03629
[50] Shinn N., Labash M., Gopinath A., Narasimhan K., Yao S. Reflexion: Language Agents with Verbal Reinforcement Learning[C]// Advances in Neural Information Processing Systems （NeurIPS）. Curran1 Associates, 2023. Available: https://arxiv.org/abs/2303.11366
[51] Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: Language Models Can Teach Themselves to Use Tools[C]// Advances in Neural Information Processing Systems （NeurIPS）. 2023.
[52] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]// International Conference on Learning Representations （ICLR）. 2023.
[53] Hong S, Zheng X, Chen J, et al. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework[C]// International Conference on Learning Representations （ICLR）. 2024.
[54] Wu Q, Bansal G, Zhang J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation[C]// International Conference on Learning Representations （ICLR）. 2024.
[55] Li G, Hammoud H A A K, Itani H, et al. CAMEL: Communicative Agents for "Mind" Exploration of Large-Scale Language Model Society[C]// Advances in Neural Information Processing Systems （NeurIPS）. 2023.
[56] Yih W, Richardson M, Meek C, et al. The Value of Semantic Parse Labeling for Knowledge Base Question Answering[C]// Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics （ACL）. 2016.
[57] Yang Z, Qi P, Zhang S, et al. HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering[C]// Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing （EMNLP）. 2018.
[58] Welbl J, Liu N F, Gardner M. Crowdsourcing Multiple Choice Science Questions[C]// Procee

dings of the 3rd Workshop on Noisy User-generated Text （W-NUT）. 2017.
[59] Jin Q, Dhingra B, Liu Z, et al. PubMedQA: A Dataset for Biomedical Research Question Ans wering[C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing （EMNLP）. 2019.
[60] Papineni K, Roukos S, Ward T, et al. BLEU: a Method for Automatic Evaluation of Machine Translation[C]// Proceedings of the 40th Annual Meeting of the Association for Computation al Linguistics （ACL）. 2002.
[61] Lin C Y. ROUGE: A Package for Automatic Evaluation of Summaries[C]// Text Summarizati on Branches Out （ACL）. 2004.
[62] Zheng L, Chiang W L, Sheng Y, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena[C]// Advances in Neural Information Processing Systems （NeurIPS）. 2024.
[63] Es S, James J, Espinosa-Anke L, et al. RAGAS: Automated Evaluation of Retrieval Augment ed Generation[C]// Proceedings of the 18th Conference of the European Chapter of the Assoc iation for Computational Linguistics （EACL）. 2024.
[64]

致谢 （Acknowledgements）